PnP AI Study

23.05.24 (Week 4)

1. Step 2-2: Dataframe 다루기
2. Step 2-3: 데이터 분석과 시각화

Dataframe - Indexing (1)

pandas.DataFrame.loc

DataFrame의 loc 프로퍼티를 이용하여
원하는 row/col을 가져올 수 있습니다.

```
# 특정 row만 가져올 때
DataFrame.loc[["인덱스", "배열"]]

# 특정 row와 col을 가져올 때
DataFrame.loc[["인덱스", "배열"], ["col", "이름", "배열"]]

# A부터 B까지의 row와 C부터 D까지의 col을 가져올 때
DataFrame.loc["A":"B", "C":"D"]
```

예제

```
# iphone.csv 파일

,출시일,디스플레이,메모리,출시 버전,Face ID
iPhone 7,2016-09-16,4.7,2GB,iOS 10.0,No
iPhone 7 Plus,2016-09-16,5.5,3GB,iOS 10.0,No
iPhone 8,2017-09-22,4.7,2GB,iOS 11.0,No
iPhone 8 Plus,2017-09-22,5.5,3GB,iOS 11.0,No
iPhone X,2017-11-03,5.8,3GB,iOS 11.1,Yes
# 이하 생략
```

```
import pandas

iphone = pandas.read_csv("iphone.csv", index_col=0)
iphone.loc["iPhone 7":"iPhone 8", ["출시일", "메모리", "출시 버전"]]
```

결과

	출시일	메모리	출시 버전
iPhone 7	2016-09-16	2GB	iOS 10.0
iPhone 7 Plus	2016-09-16	3GB	iOS 10.0
iPhone 8	2017-09-22	2GB	iOS 11.0

iPhone7부터 iPhone8 까지의 출시일, 메모리, 출시 버전을 출력

DataFrame - Indexing (2)

파이썬 상식 - 매직 메소드 `__getitem__`

파이썬에서 객체에 []를 이용해서 접근하려고 하면
(ex: `some_array[1]`, `some_dict["key_name"]` 등)
파이썬 내부적으로는 `__getitem__` 메소드를 호출합니다.

즉, `some_array[1]`을 실행하면 파이썬 내부에서는
`some_array.__getitem__(1)`으로 변환되어 작동한다는 소리죠.

pandas에서는 이를 이용하여 쉽고 빠르게
특정 column만을 가져올 수 있도록 되어있습니다.

pandas.DataFrame.__getitem__

DataFrame의 `__getitem__`을 이용하면
빠르게 column을 필터링 할 수 있습니다.

예제

```
# import, read_csv 생략

iphone[["출시일", "출시 버전"]]
```

결과

	출시일	출시 버전
iPhone 7	2016-09-16	iOS 10.0
iPhone 7 Plus	2016-09-16	iOS 10.0
iPhone 8	2017-09-22	iOS 11.0
iPhone 8 Plus	2017-09-22	iOS 11.0
iPhone X	2017-11-03	iOS 11.1
iPhone XS	2018-09-21	iOS 12.0
iPhone XS Max	2018-09-21	iOS 12.0

column 중 출시일, 출시 버전만 출력

DataFrame - Filtering (조건부 인덱싱) (1)

pandas에서 DataFrame.loc 프로퍼티에 boolean 타입의 배열을 넣어주면 True인 위치의 값만 가져올 수 있습니다.

```
iphone.loc[[True, False, True, False, True, False, True]]
```

> 주의: index 부분에는 index의 길이와 같은 크기의 boolean 배열을, column 부분에는 column의 길이와 같은 크기의 배열을 넣어줘야 합니다.

결과

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	No
iPhone 8	2017-09-22	4.7	2GB	iOS 11.0	No
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes

값이 True인 0, 2, 4, 6번째의 값만 출력

DataFrame - Filtering (조건부 인덱싱) (2)

pandas의 DataFrame의 column의 Series는
(ex: `iphone["출시일"]`의 경우 "출시일" column의 Series)
비교 연산 (>, ==, < 등)을 하면 해당 결과를
모든 row에 대해 연산한 Series를 반환해줍니다.
이를 이용하면 DataFrame의 필터링에 유용하게 사용 가능합니다.

비교연산 예제

```
iphone["Face ID"] == "Yes"
```

	Face ID
iPhone 7	False
iPhone 7 Plus	False
iPhone 8	False
iPhone 8 Plus	False
iPhone X	True
iPhone XS	True
iPhone XS Max	True

Face ID가 Yes인 값만 True인 pandas.Series를 출력

비교연산을 이용한 필터링

```
has_face_id = iphone["Face ID"] == "Yes"
iphone.loc[has_face_id]
```

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes

Face ID가 Yes인 row만 출력

다중 조건 필터링

Series끼리도 비교 연산이 가능하다는 점을 이용하면
조건이 여러개여도 필터링이 가능합니다.

예제

```
has_face_id = iphone["Face ID"] == "Yes"
big_display = iphone["디스플레이"] > 5.5
iphone.loc[(has_face_id & big_display)]
```

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes

Face ID가 Yes이고 디스플레이가 5.5보다 큰 값만 출력

DataFrame - Indexing (3)

pandas.DataFrame.iloc

loc와 기본적으로 비슷하지만,
위치를 기반으로 Indexing이 가능합니다.

“ 참고: 일반적인 list와 같이 0번부터 시작합니다. ”

예제

```
iphone.iloc[[1, 3], [2, 3]]
```

	메모리	출시 버전
iPhone 7 Plus	3GB	iOS 10.0
iPhone 8 Plus	3GB	iOS 11.0

1, 3번의 row, 2, 3번의 column이 출력됨

DataFrame - Writing (1)

pandas.DataFrame.__setitem__

단순히 `__getitem__`와는 반대로 작동하는 매직 메소드.

`some_arr[1] = "Someting"`의 경우에는
`some_arr.__setitem__(1, "Something")`으로 변환되어 작동됩니다.

이를 이용해서 Indexing, Filtering 등으로
선택한 DataFrame에 대입 연산자를 통해 값을 넣어주면
그 값이 원본의 DataFrame에도 반영됩니다.

예제

```
has_face_id = iphone["Face ID"] == "Yes"

iphone.loc[has_face_id, "Face ID"] = True
iphone.loc[~has_face_id, "Face ID"] = False      # Python에서 '~'는 비트연산 Not을 의미

iphone
```

결과

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	False
iPhone 7 Plus	2016-09-16	5.5	3GB	iOS 10.0	False
iPhone 8	2017-09-22	4.7	2GB	iOS 11.0	False
iPhone 8 Plus	2017-09-22	5.5	3GB	iOS 11.0	False
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	True
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	True
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	True

Face ID가 Yes인 row는 True로,
Yes가 아닌 row는 False로 값이 바뀜

DataFrame - Writing (2)

위와 같지만, column이 존재하지 않는다면
자동으로 새 column을 생성합니다.

예제

```
iphone["출시 가격"] = 1000000
```

결과

	출시일	디스플레이	메모리	출시 버전	Face ID	출시 가격
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	No	1000000
iPhone 7 Plus	2016-09-16	5.5	3GB	iOS 10.0	No	1000000
iPhone 8	2017-09-22	4.7	2GB	iOS 11.0	No	1000000
iPhone 8 Plus	2017-09-22	5.5	3GB	iOS 11.0	No	1000000
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes	1000000
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes	1000000
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes	1000000

자동으로 출시 가격 column을 생성하여 대입함

DataFrame - Deleting

pandas.DataFrame.drop

DataFrame의 drop 메소드를 이용하면 원하는 row/column을 삭제 가능합니다.

```
# some_dataframe에서 "인덱스", "리스트" row를 삭제한 DataFrame 반환
some_dataframe.drop(["인덱스", "리스트"], axis="index")

# some_dataframe에서 "column", "list" column을 삭제한 DataFrame 반환
some_dataframe.drop(["column", "list"], axis="columns")
```

drop 메소드 인수로 `inplace=True`를 추가해 주면 원본 DataFrame에도 적용됩니다.

예제 1

```
iphone.drop(["iPhone 8"], axis="index", inplace=True)
iphone
```

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	No
iPhone 7 Plus	2016-09-16	5.5	3GB	iOS 10.0	No
iPhone 8 Plus	2017-09-22	5.5	3GB	iOS 11.0	No
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes

iPhone 8이 삭제되서 출력

예제 2

```
iphone.drop(["출시 버전"], axis="columns", inplace=True)
iphone
```

	출시일	디스플레이	메모리	Face ID
iPhone 7	2016-09-16	4.7	2GB	No
iPhone 7 Plus	2016-09-16	5.5	3GB	No
iPhone 8	2017-09-22	4.7	2GB	No
iPhone 8 Plus	2017-09-22	5.5	3GB	No
iPhone X	2017-11-03	5.8	3GB	Yes
iPhone XS	2018-09-21	5.8	4GB	Yes
iPhone XS Max	2018-09-21	6.5	4GB	Yes

출시 버전 column이 삭제되서 출력

DataFrame - Renaming

pandas.DataFrame.rename

DataFrame의 rename 메소드를 이용하면 column의 이름을 변경할 수 있습니다.

```
# "column"은 "열"로, "name"은 "이름"으로 column 이름을 변경
some_dataframe.rename(columns={
    "column": "열",
    "name": "이름"
})
```

rename 메소드도, 인수에 `inaple=True`를 추가해 주면 원본 DataFrame에 적용됩니다.

예제

```
iphone.rename(columns={
    "출시일": "Release Date"
}, inplace=True)
iphone
```

	Release Date	디스플레이	메모리	출시 버전	Face ID
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	No
iPhone 7 Plus	2016-09-16	5.5	3GB	iOS 10.0	No
iPhone 8	2017-09-22	4.7	2GB	iOS 11.0	No
iPhone 8 Plus	2017-09-22	5.5	3GB	iOS 11.0	No
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes

출시일이 Release Date로 변경되어 출력

DataFrame - Index 변경

pandas.DataFrame.set_index

DataFrame의 set_index 메소드를 통해
Index로 사용할 column을 지정해 줄 수 있습니다.

```
# set_dataframe의 "column_name" column을 index로 설정
some_dataframe.set_index("column_name")
```

이것 역시 인수에 `inplace=True`를 넣어주면
원본 DataFrame에 반영됩니다.

예제

```
iphone.set_index("출시일", inplace=True)
iphone
```

출시일	디스플레이	메모리	출시 버전	Face ID
2016-09-16	4.7	2GB	iOS 10.0	No
2016-09-16	5.5	3GB	iOS 10.0	No
2017-09-22	4.7	2GB	iOS 11.0	No
2017-09-22	5.5	3GB	iOS 11.0	No
2017-11-03	5.8	3GB	iOS 11.1	Yes
2018-09-21	5.8	4GB	iOS 12.0	Yes
2018-09-21	6.5	4GB	iOS 12.0	Yes

출시일 column이 index로 변경되어 출력

다만, 이러면 원래의 Index가 사라져서 이용할 수 없게 됩니다.
이럴때는 index를 새로운 column으로 지정해 주면 문제가 해결됩니다.

```
iphone["Name"] = iphone.index    # 원래 인덱스를 Name column으로 지정
iphone.set_index("출시일", inplace=True)    # 그 후 출시일을 index로 사용
iphone
```

출시일	디스플레이	메모리	출시 버전	Face ID	Name
2016-09-16	4.7	2GB	iOS 10.0	No	iPhone 7
2016-09-16	5.5	3GB	iOS 10.0	No	iPhone 7 Plus
2017-09-22	4.7	2GB	iOS 11.0	No	iPhone 8
2017-09-22	5.5	3GB	iOS 11.0	No	iPhone 8 Plus
2017-11-03	5.8	3GB	iOS 11.1	Yes	iPhone X
2018-09-21	5.8	4GB	iOS 12.0	Yes	iPhone XS
2018-09-21	6.5	4GB	iOS 12.0	Yes	iPhone XS Max

DataFrame - head/tail

pandas.DataFrame.head

DataFrame의 위쪽 n개의 row만 선택하는 메소드

pandas.DataFrame.tail

DataFrame의 아래쪽 n개의 row만 선택하는 메소드

예제 - head

```
iphone.head(3)
```

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	No
iPhone 7 Plus	2016-09-16	5.5	3GB	iOS 10.0	No
iPhone 8	2017-09-22	4.7	2GB	iOS 11.0	No

위쪽 3개만 출력

예제 - tail

```
iphone.tail(3)
```

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes

아래쪽 3개만 출력

DataFrame - shape/info/describe

pandas.DataFrame.shape

DataFrame의 모양 (행/열 개수)을 확인할 수 있는 프로퍼티

pandas.DataFrame.info

DataFrame의 정보 (column별 개수, 타입 등)을 확인하는 메소드

pandas.DataFrame.describe

DataFrame의 각 column의 통계값을 확인하는 메소드

DataFrame - Sorting

pandas.DataFrame.sort_values

DataFrame을 Sort (정렬)하는 메소드

```
# some_dataframe을 "column_name" column의 값에 따라 정렬 (오름차순)
some_dataframe.sort_values(by="column_name")

# some_dataframe을 "column_name" column의 값에 따라 정렬 (내림차순)
some_dataframe.sort_values(by="column_name", ascending=False)
```

역시 `inplace=True`를 해주면 원본 DataFrame을 정렬합니다.

예제

```
iphone.sort_values("디스플레이", ascending=False)
```

	출시일	디스플레이	메모리	출시 버전	Face ID
iPhone XS Max	2018-09-21	6.5	4GB	iOS 12.0	Yes
iPhone X	2017-11-03	5.8	3GB	iOS 11.1	Yes
iPhone XS	2018-09-21	5.8	4GB	iOS 12.0	Yes
iPhone 7 Plus	2016-09-16	5.5	3GB	iOS 10.0	No
iPhone 8 Plus	2017-09-22	5.5	3GB	iOS 11.0	No
iPhone 7	2016-09-16	4.7	2GB	iOS 10.0	No
iPhone 8	2017-09-22	4.7	2GB	iOS 11.0	No

디스플레이 내림차순으로 정렬되어 출력

Series - unique/value_counts

pandas.Series.unique

Series의 중복된 값을 제거해서 알려주는 메소드

pandas.Series.value_counts

Series에 중복된 값의 개수를 알려주는 메소드

예제 - unique

```
iphone["출시 버전"].unique()
```

	0
0	iOS 10.0
1	iOS 11.0
2	iOS 11.1
3	iOS 12.0

출시 버전 중 unique한 값만 출력

“ 참고: unique()의 return 타입은 numpy array ”

예제 - value_counts

```
iphone["출시 버전"].value_counts()
```

출시 버전	count
iOS 10.0	2
iOS 11.0	2
iOS 12.0	2
iOS 11.1	1

출시 버전의 중복된 값의 개수를 출력

“ 참고: value_counts()의 return 타입은 pandas.Series ”

DataFrame - Data Visualization

단순한 표 (DataFrame)을 통해서는
데이터가 의미하는 바를 직관적으로 알아보기 힘듭니다.

데이터 시각화를 통해 단순한 데이터(표)를
차트, 그래프 등과 같은 시각적 요소로 표현함으로써
데이터를 더 쉽게 이해하고 활용할 수 있습니다.

DataFrame - plot

pandas.DataFrame.plot

pandas DataFrame의 plot 메소드를 통해 쉽고 빠르게 데이터 시각화를 할 수 있습니다.
`some_dataframe.plot(kind="plot_종류")` 형태로 사용하며 plot 종류는 다음과 같습니다.

* line (선 그래프)
* bar (막대 그래프)
* barh (수평 막대 그래프)
* hist (히스토그램)
* box (박스 그래프)
* kde (밀도 분포 그래프)
* area (영역 그래프)
* pie (파이 그래프)
* scatter (분산 그래프 / 산점도)
* hexbin (육각형 그래프)

Data Visualization - Line Plot

선 그래프를 이용하면 값의 변화량을 파악하기 용이합니다.

	KBS	MBC	SBS	TV CHOSUN	JTBC	Channel A	MBN
2011	35.951	18.374	11.173	9.102	7.380	3.771	2.809
2012	36.163	16.022	11.408	8.785	7.878	5.874	3.310
2013	31.989	16.778	9.673	9.026	7.810	5.350	3.825
2014	31.210	15.663	9.108	9.440	7.490	5.776	4.572
2015	27.777	16.573	9.099	9.940	7.267	6.678	5.520
2016	27.583	14.982	8.669	9.829	7.727	6.624	5.477
2017	26.890	12.465	8.661	8.886	9.453	6.056	5.215

위와 같은 DataFrame을 예제로 봅시다.

예제 - Line Plot

```
broadcast.plot(kind="line")
```

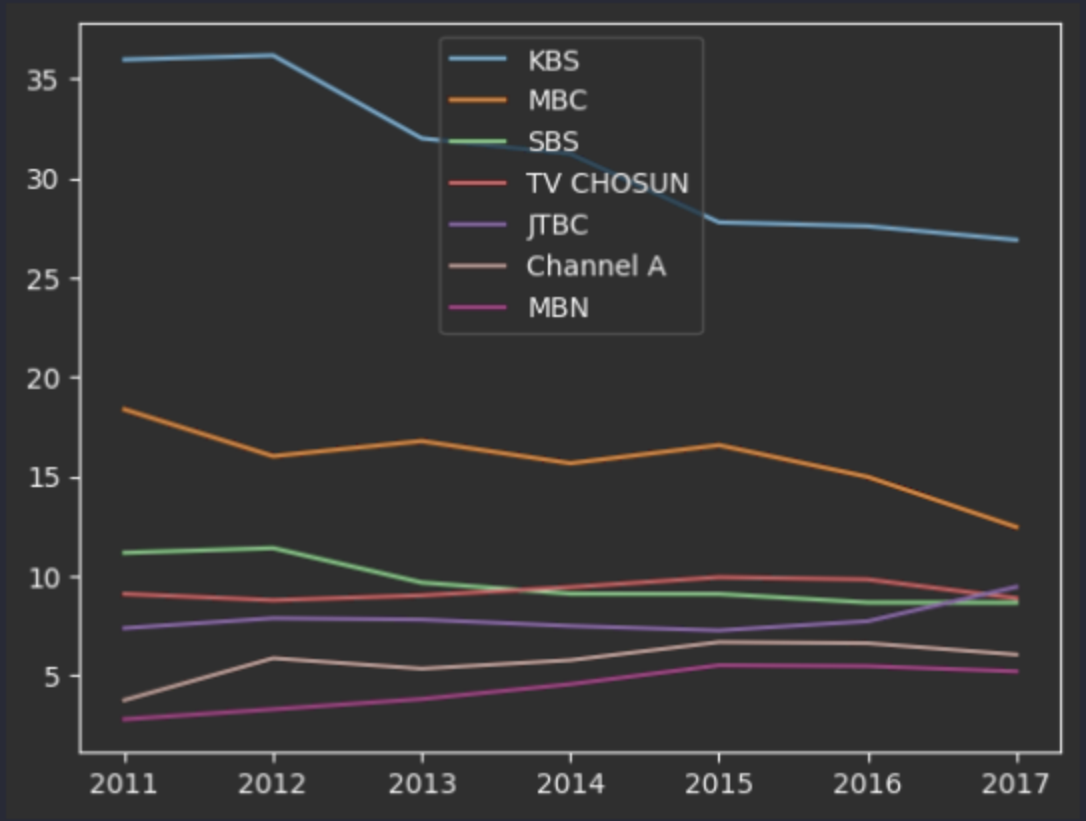

plot()에 y인수를 이용하면 column을 필터링 가능합니다.

```
broadcast.plot(kind="line", y=["KBS", "MBC"])
```

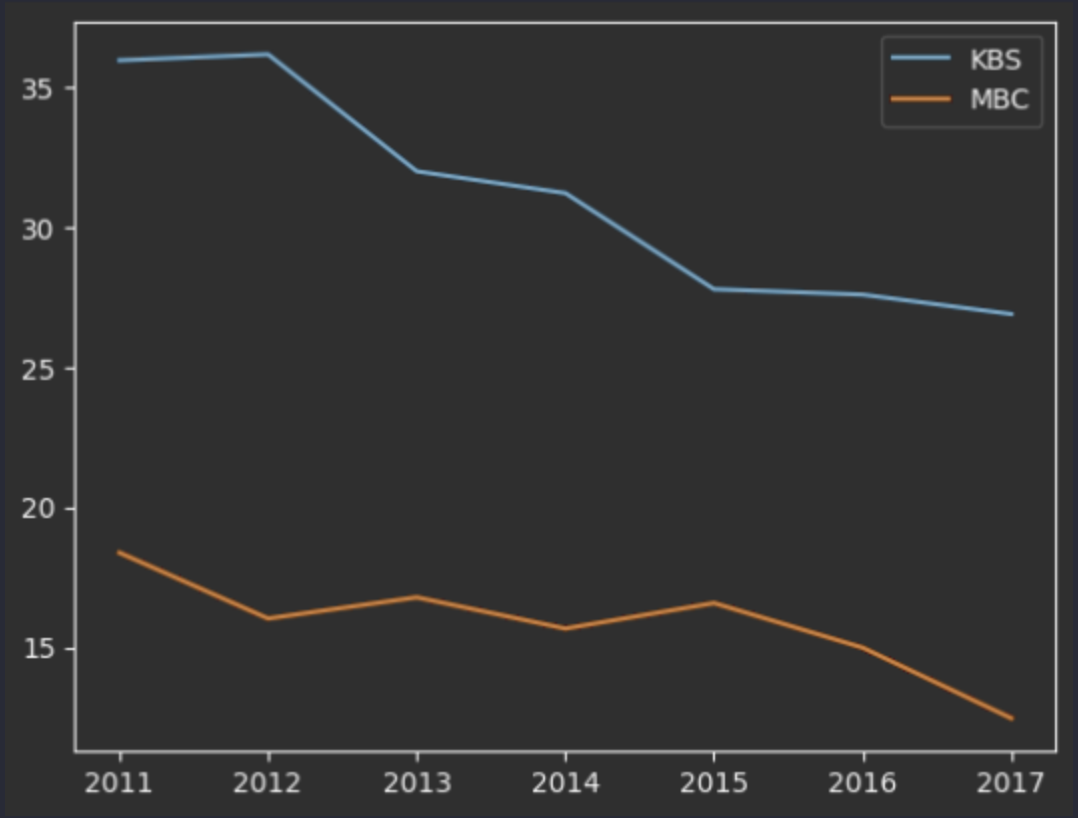

Data Visualization - Bar Plot

막대 그래프를 이용하면 양, 대소관계 등을 파악하기 용이합니다.

	Male	Female
Swimming	103	178
Baseball	363	289
Basketball	151	97
Golf	154	232
Soccer	413	109
Bowling	88	129

위와 같은 DataFrame을 예제로 봅시다.

예제 - Bar Plot

```
sports.plot(kind="bar")
```

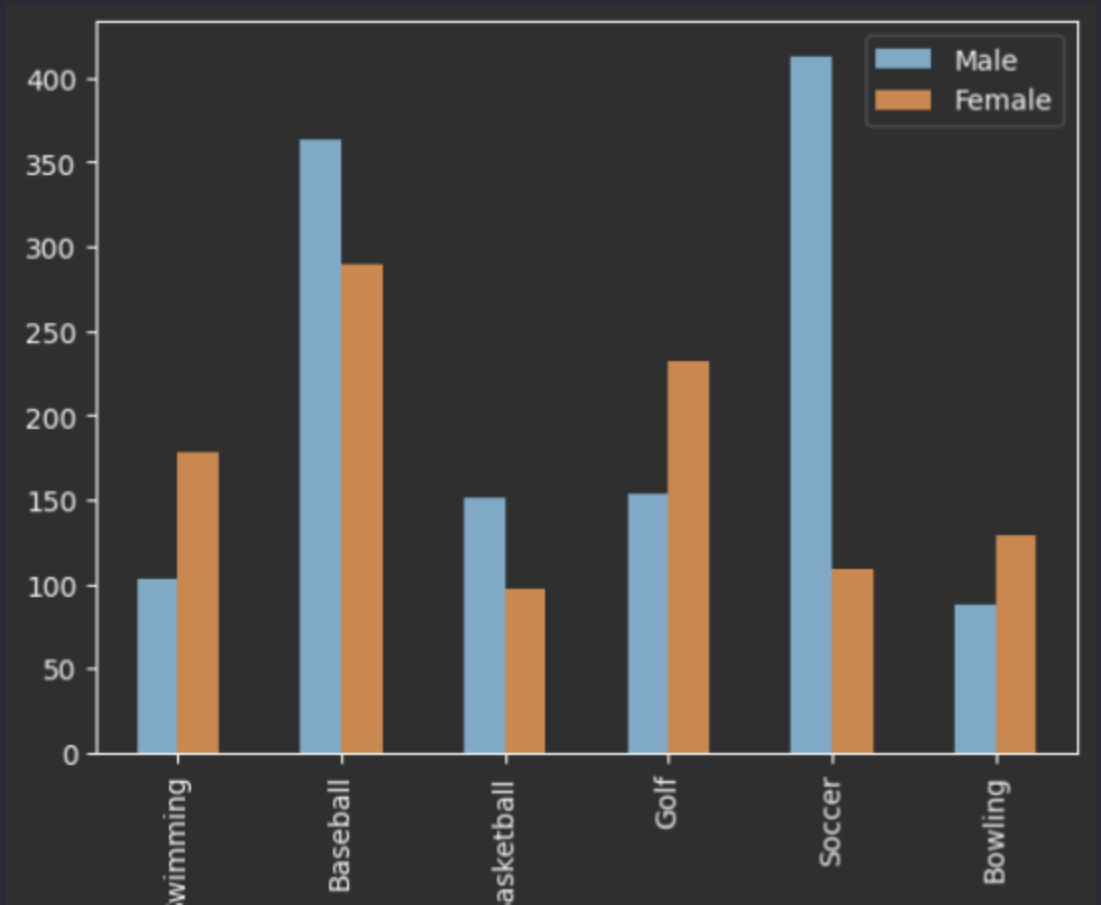

`stacked=True`를 이용하면 그래프를 겹쳐서 그릴 수 있습니다.

```
sports.plot(kind="bar", stacked=True)
```

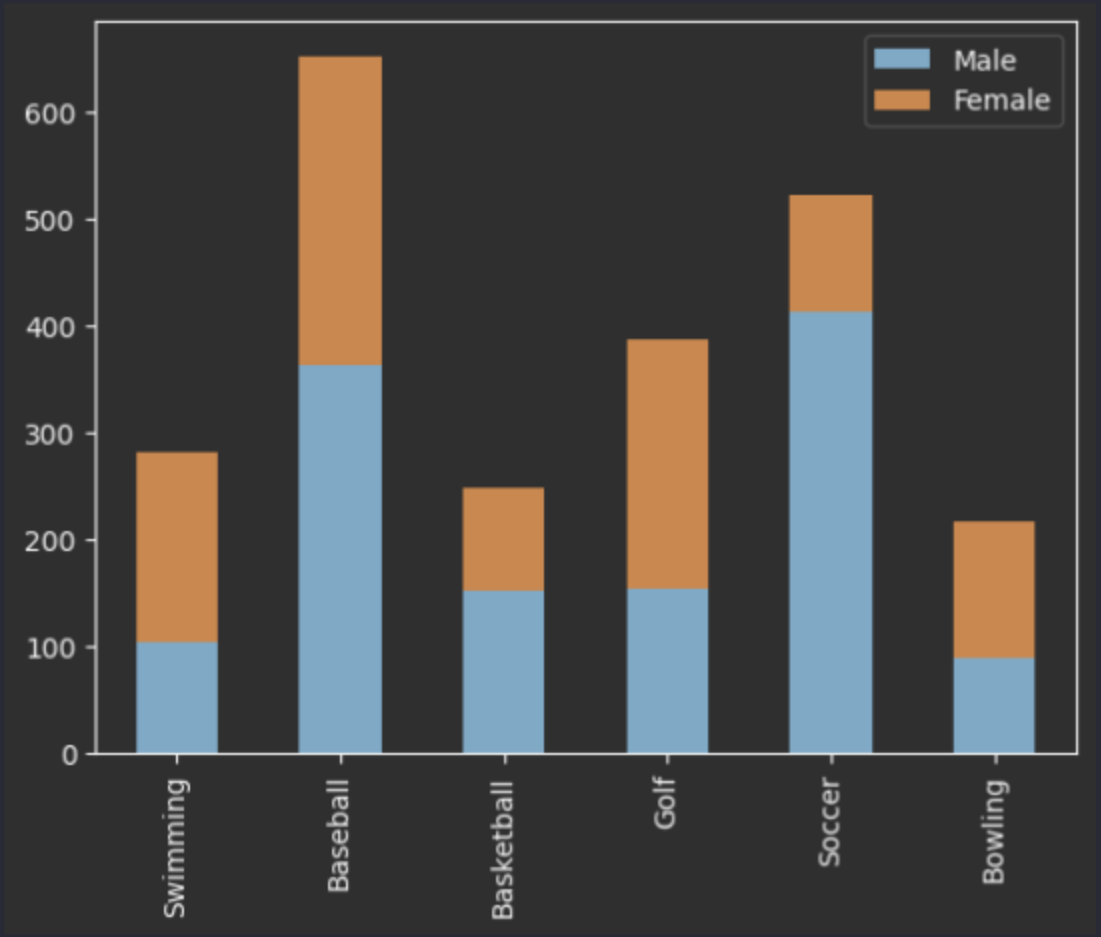

Data Visualization - Pie Plot

파이 그래프를 이용하면 비율을 비교하기에 용이합니다.

	KBS	MBC	SBS	TV CHOSUN	JTBC	Channel A	MBN
2011	35.951	18.374	11.173	9.102	7.380	3.771	2.809
2012	36.163	16.022	11.408	8.785	7.878	5.874	3.310
2013	31.989	16.778	9.673	9.026	7.810	5.350	3.825
2014	31.210	15.663	9.108	9.440	7.490	5.776	4.572
2015	27.777	16.573	9.099	9.940	7.267	6.678	5.520
2016	27.583	14.982	8.669	9.829	7.727	6.624	5.477
2017	26.890	12.465	8.661	8.886	9.453	6.056	5.215

위의 DataFrame을 다시 예제로 사용해서 봅시다.

예제 - Pie Plot

```
broadcast.loc[2011].plot(kind="pie")     # 2011년의 시청률을 비교
```

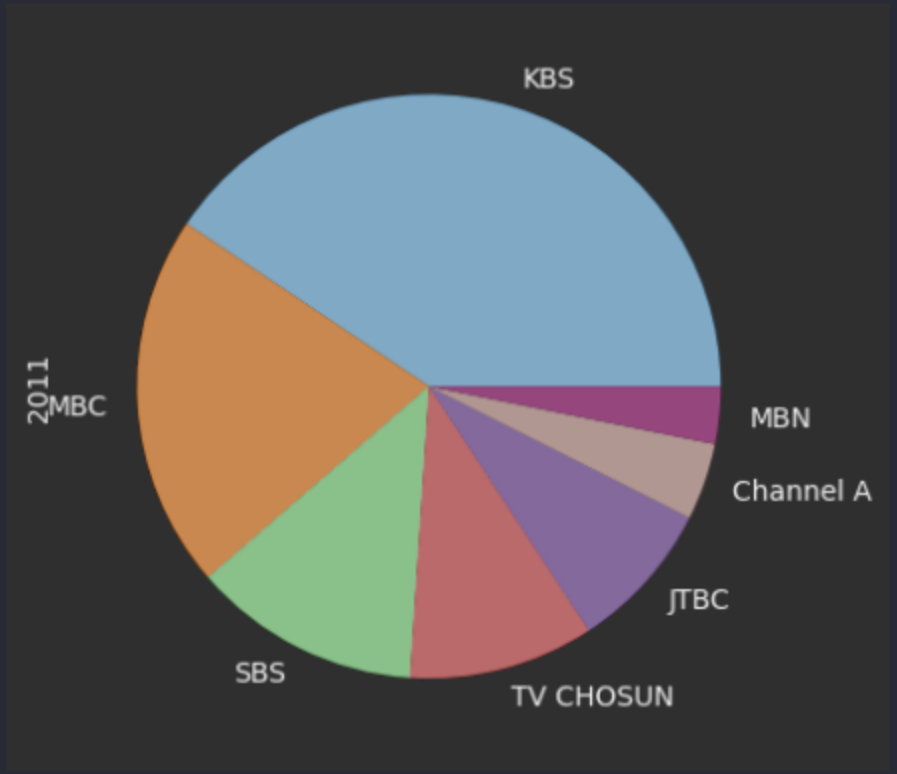

Data Visualization - Histogram Plot

히스토그램을 이용하면 데이터의 분포를 파악하기 용이합니다.

Number	Height	Weight
1	176.0	85.2
2	175.3	67.7
3	168.6	75.2
4	168.1	67.1
5	175.3	63.0
6	175.4	72.7
7	181.5	87.9

위의 DataFrame을 예시로 봅시다.

예제 - Histogram Plot

```
body["Height"].plot(kind="hist")     # 키의 분포를 확인
```

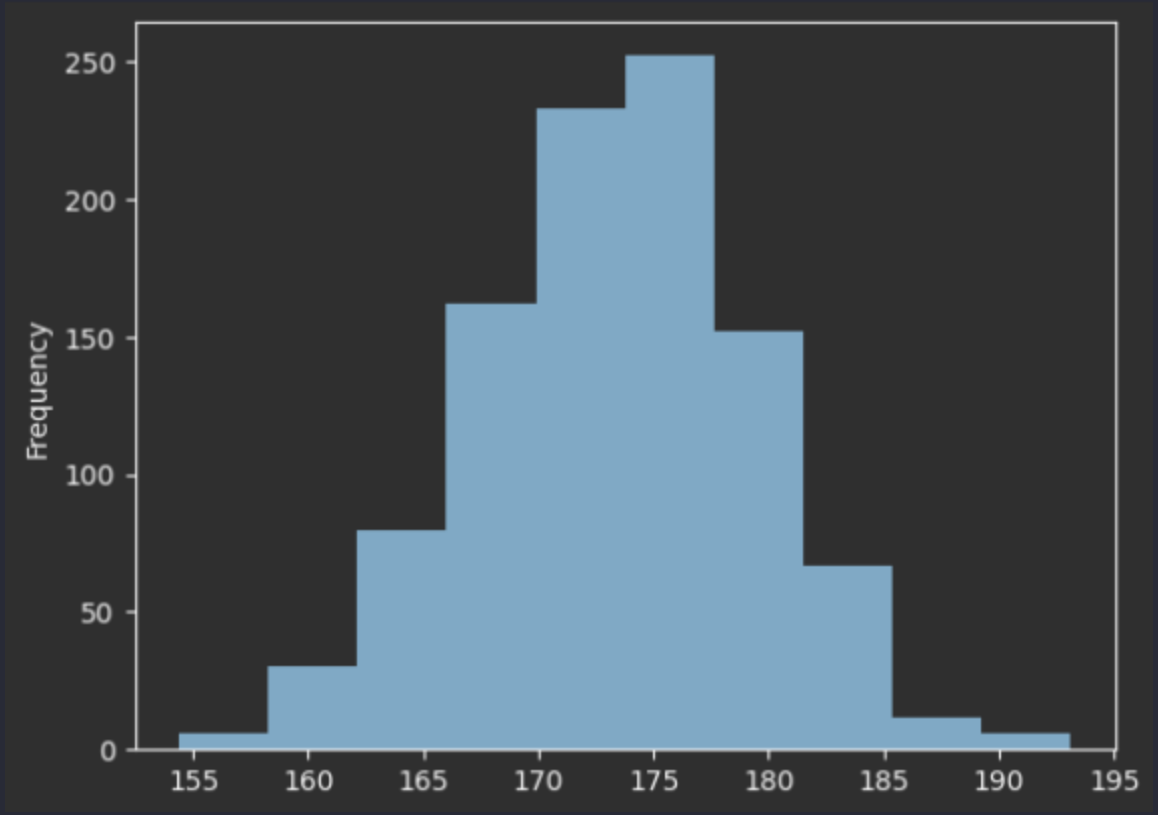

bins 인수로 히스토그램을 몇개로 나눌지 설정 가능합니다.

```
body["Height"].plot(kind="hist", bins=20)    # 히스토그램을 20개로 나눔
```

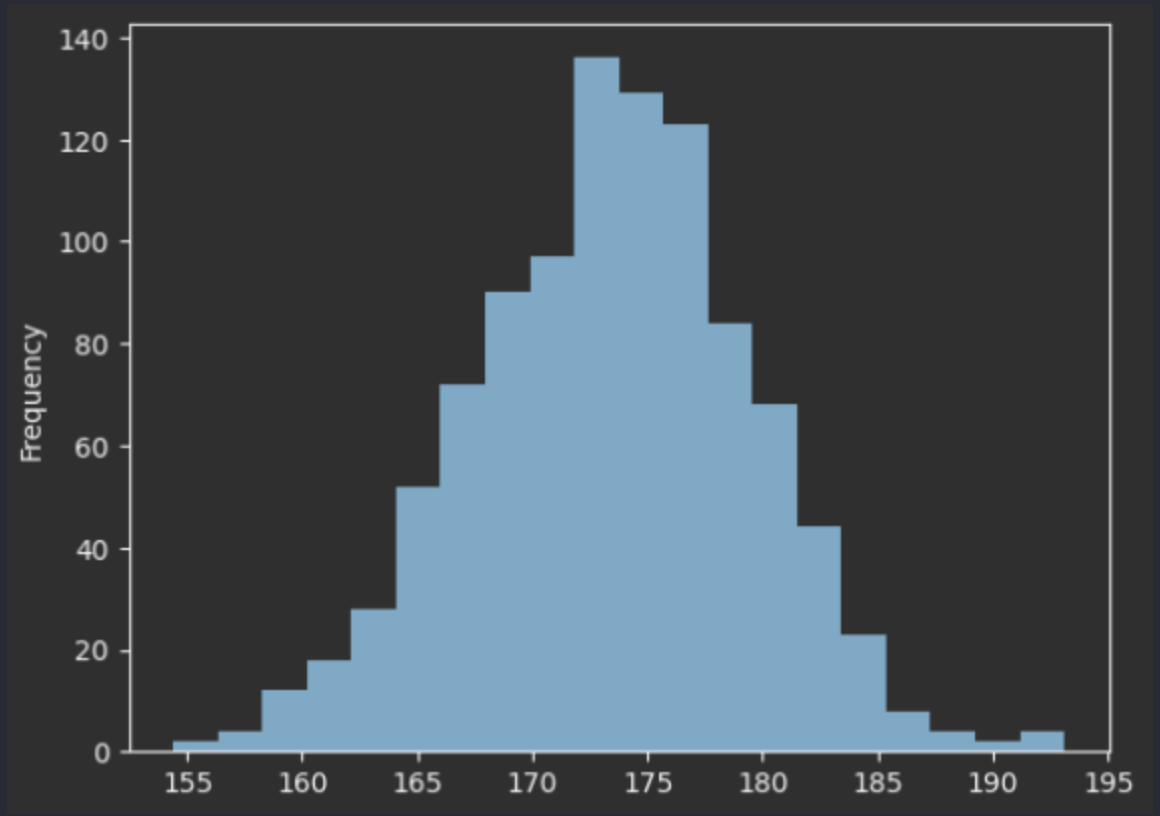

Data Visualization - Bot Plot

박스 플롯을 이용하면 데이터가 분포된 정도와 이상치 (outlier)를 쉽게 확인 가능합니다.

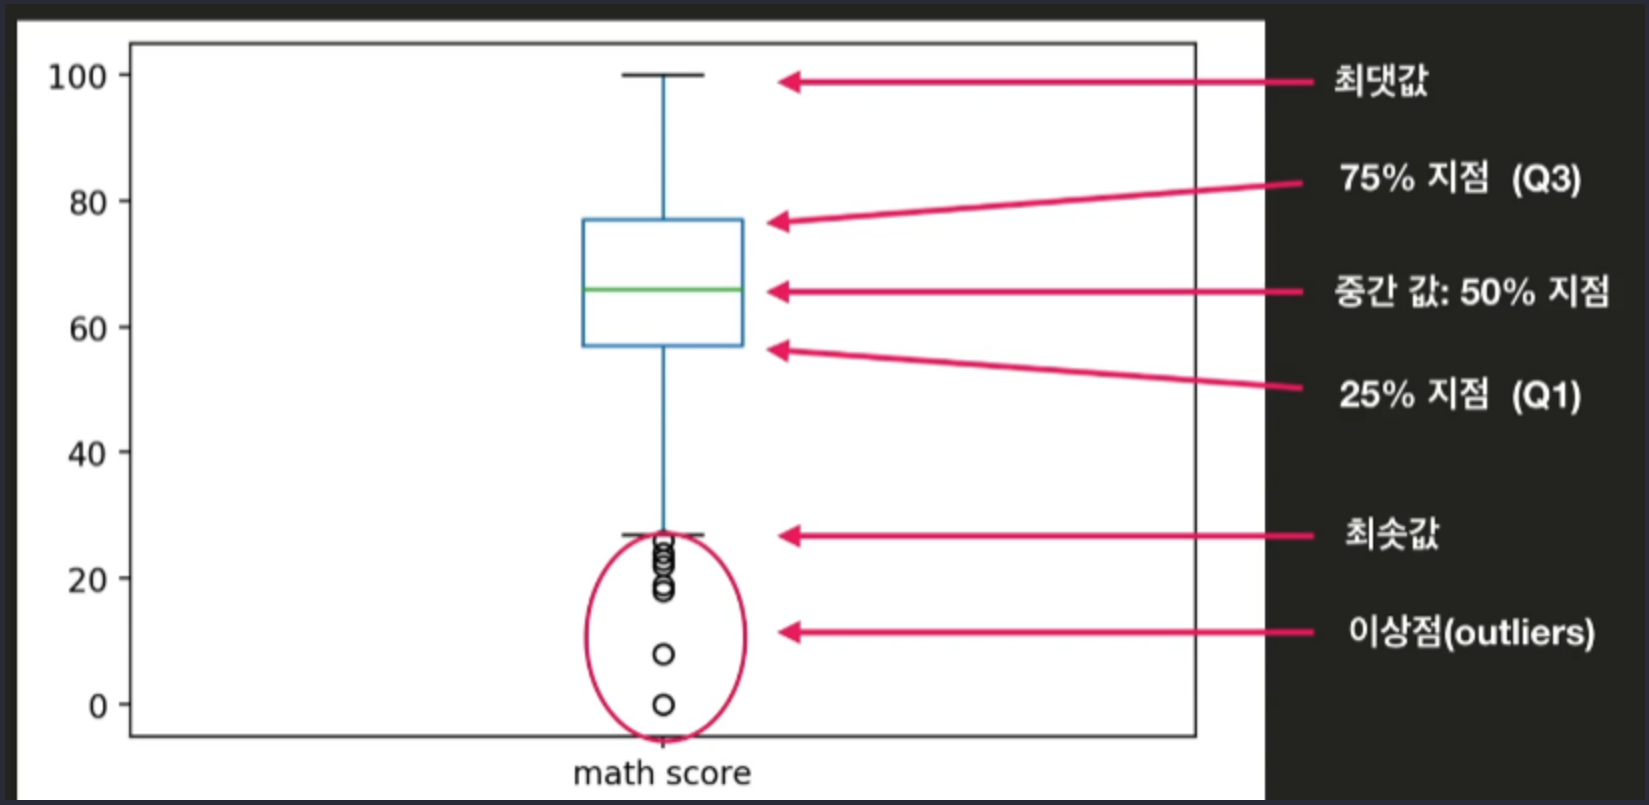

참고: 박스 플롯이 생소할수도 있는데
주식 차트도 자세히 보면 박스 플롯입니다.

예제 - Box Plot

```
exam.info()   exam: DataFrame (1000, 8)
```

26ms 내의 2023.05.24 00:24:07에서 실행되었습니다

```
   #   Column                       Non-Null Count  Dtype
  ---  ------                       --------------  -----
   0   gender                       1000 non-null   object
   1   race/ethnicity               1000 non-null   object
   2   parental level of education  1000 non-null   object
   3   lunch                        1000 non-null   object
   4   test preparation course      1000 non-null   object
   5   math score                   1000 non-null   int64
   6   reading score                1000 non-null   int64
   7   writing score                1000 non-null   int64
```

다음과 같은 DataFrame을 예시로 봅시다.

예제 - Box Plot

```
# 수학, 읽기, 쓰기 점수를 박스 플롯으로 표시
exam.plot(kind="box", y=["math score", "reading score", "writing score"])
```

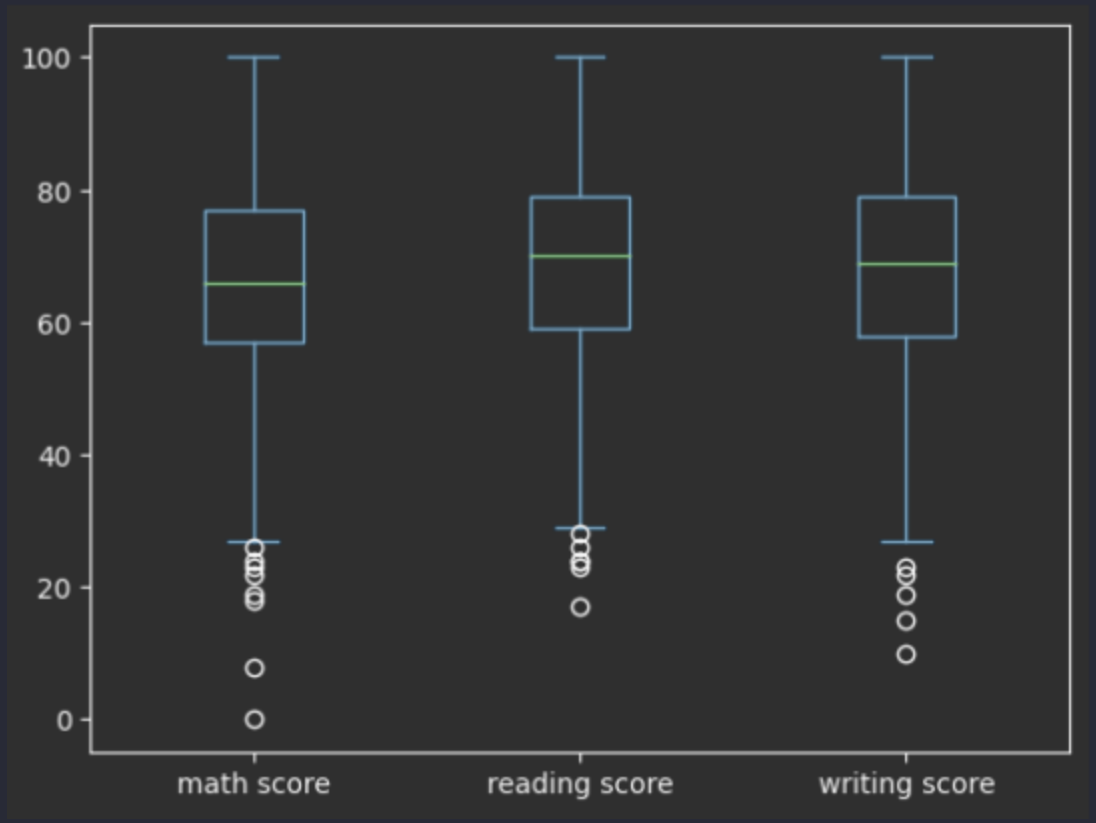

Data Visualization - Scatter Plot

분산 그래프 (산점도)를 이용하면 지표의 상관관계를 파악하기 용이합니다.

```
exam.info()   exam: DataFrame (1000, 8)
```

26ms 내의 2023.05.24 00:24:07에서 실행되었습니다

```
   #   Column                       Non-Null Count  Dtype
  ---  ------                       --------------  -----
   0   gender                       1000 non-null   object
   1   race/ethnicity               1000 non-null   object
   2   parental level of education  1000 non-null   object
   3   lunch                        1000 non-null   object
   4   test preparation course      1000 non-null   object
   5   math score                   1000 non-null   int64
   6   reading score                1000 non-null   int64
   7   writing score                1000 non-null   int64
```

다시 위의 DataFrame을 예시로 봅시다.

예시 - Scatter Plot

```
# 수학 점수와 읽기 점수의 상관관계를 분석
exam.plot(kind="scatter", y="math score", x="reading score")
```

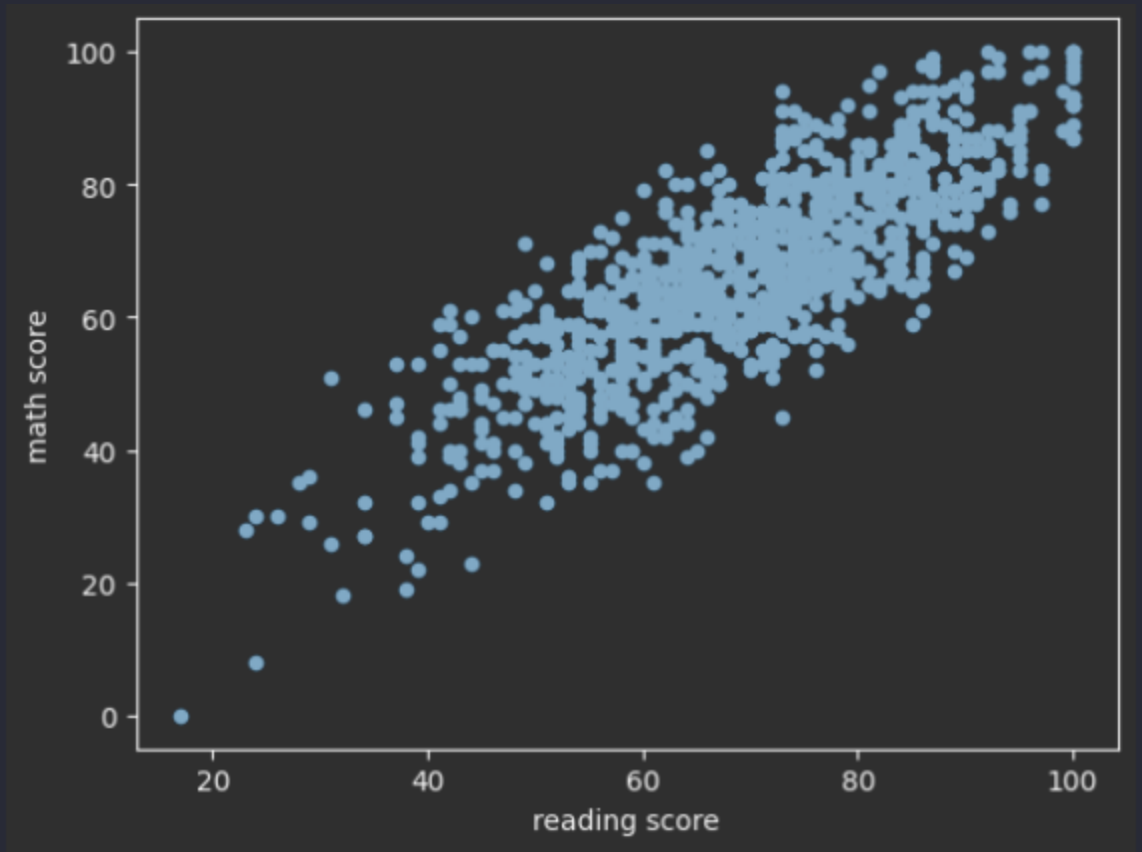

Seaborn

pandas보다 더 다양한 그래프를 그릴 수 있게 해주는 데이터 시각화 라이브러리.

`pip install seaborn` 으로 설치합니다.

참고:

- pipenv: `pipenv install seaborn`
- anaconda: `conda install seaborn`
- poetry: `poetry add seaborn`

Probability Density Function (확률 밀도 함수)

분포도의 특정 범위에서 값이 존재할 확률을 나타내는 함수
위 함수를 그래프로 그리면 값의 분포를 알기 쉽습니다.

Kernel Density Estimation (커널 밀도 추정)

PDF와 KDE를 이용해 튀는 값을 뭉개서
분포도를 부드럽게 그릴 수 있습니다.

예제: KDE Plot

Number	Height	Weight
1	176.0	85.2
2	175.3	67.7
3	168.6	75.2
4	168.1	67.1
5	175.3	63.0
6	175.4	72.7
7	181.5	87.9

위의 DataFrame을 다시 예제로 봅시다.

예제: KDE Plot

우선 단순 분포도를 그려봅시다.

```
height = body["Height"].value_counts().sort_index().plot(kind="line")
```

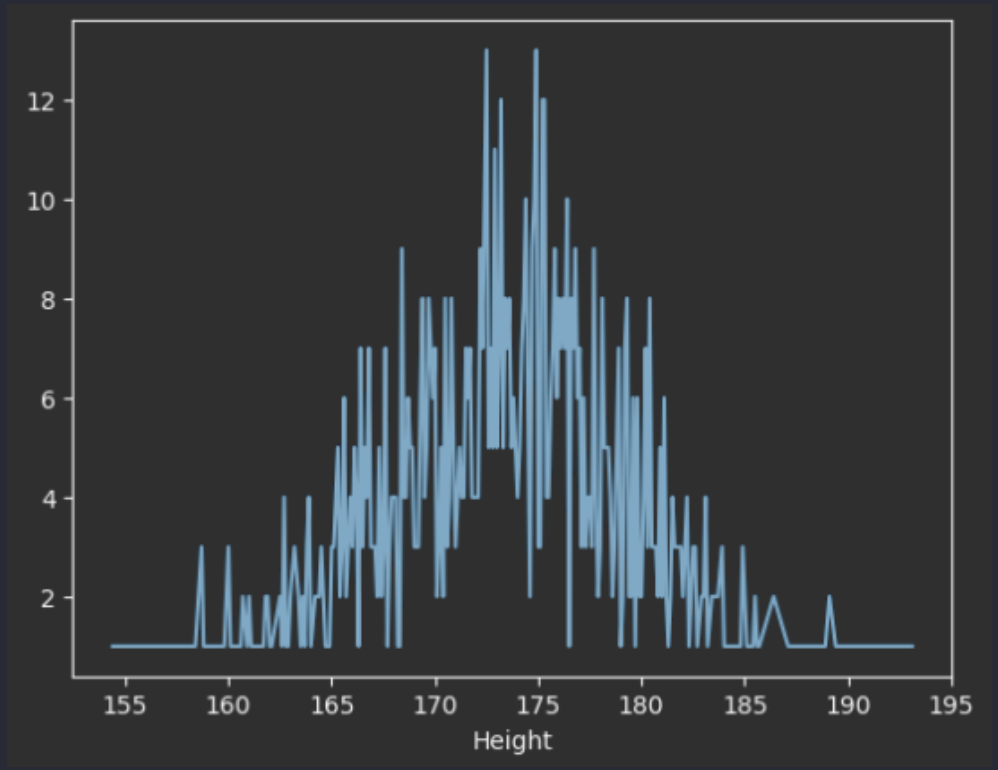

예제: KDE Plot

그래프가 튀는 값에 의해
보기 어렵게 그려지는것을 볼 수 있습니다.

이걸 KDE Plot으로 바꾸려면 다음과 같습니다.

```
import seaborn
# read_csv 생략
seaborn.kdeplot(body["Height"])
```

결과: KDE Plot

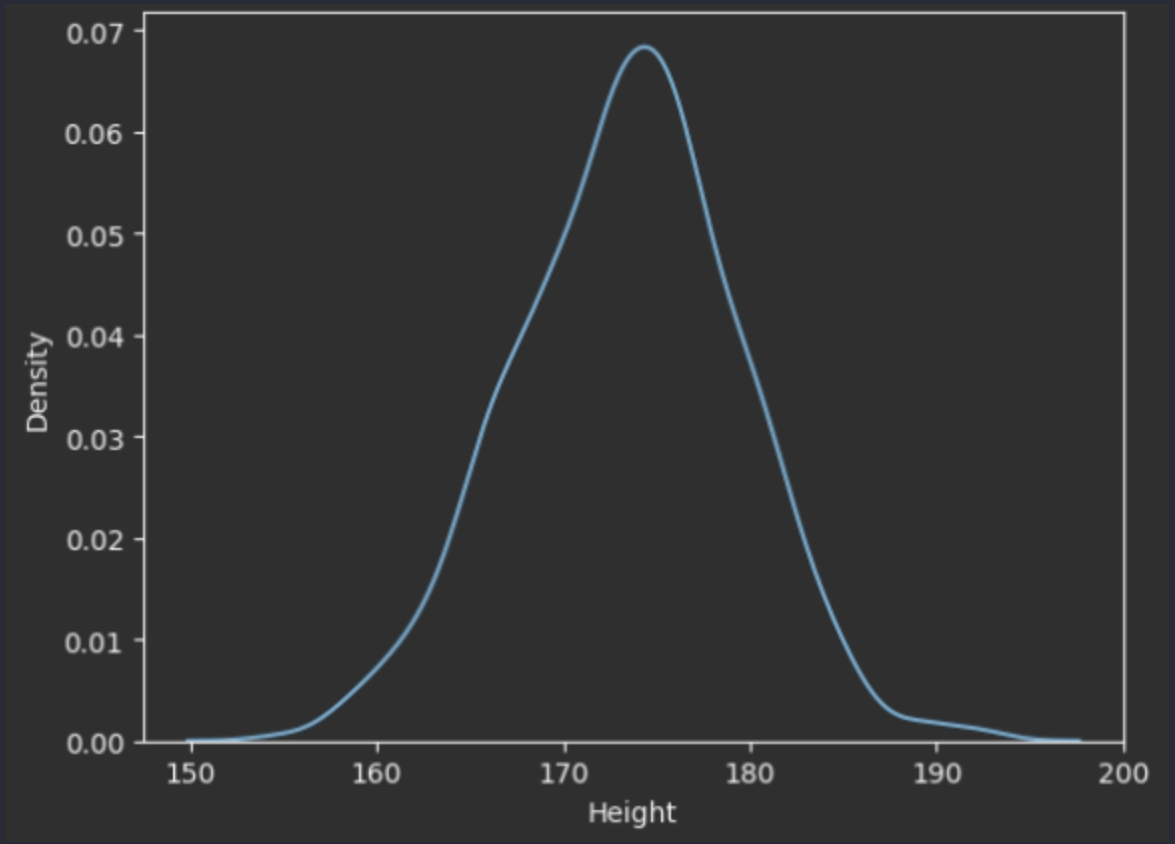

단순 분포도보다 완만한 곡선으로 더 보기 쉬워진것을 알 수 있습니다.

KDE - Bandwidth

KDE 함수의 Bandwidth 값을 조절하여
그래프의 뾰족한 정도를 결정할 수 있습니다.

`seaborn.kdeplot()` 메소드에서는 `bw` 인수로 구현되어 있습니다.

예제: KDE Plot Bandwidth

```
seaborn.kdeplot(body["Height"], bw=0.1)
```

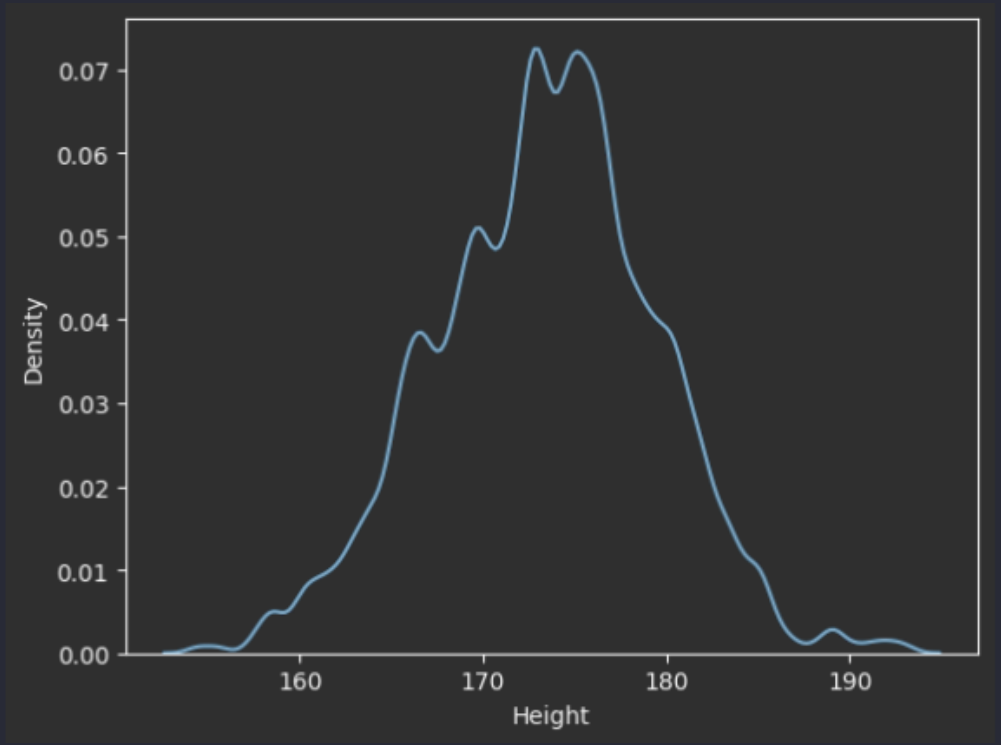

처음보다 더 뾰족해지는 것을 확인할 수 있습니다.

Seaborn - KDE Plot with Histogram

히스토그램과 KDE 그래프를 같이 그려 비교하기 쉽게 만들수 있습니다.

주의: Seaborn v0.14.0부터 distplot 메소드는 deprecated 되었습니다.

seaborn.histplot 메소드에 `kde=True` 인수를 넣어
히스토그램과 KDE를 동시에 그릴 수 있습니다.

```
seaborn.histplot(some_dataframe, kde=True)
```

예제: KDE Plot with Histogram

```
seaborn.histplot(body["Height"], kde=True)
```

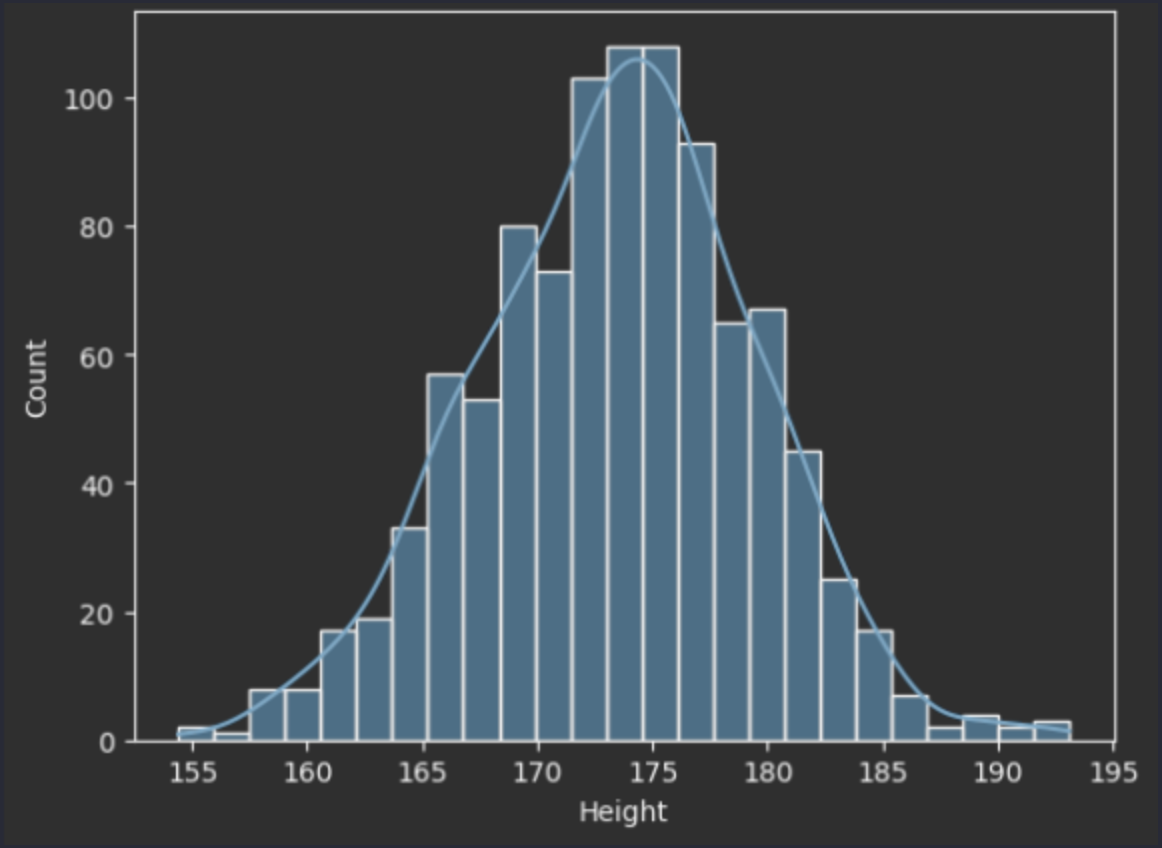

Seaborn - Violin Plot

바이올린 플롯은 Box Plot처럼 최대/최소값을 보기 쉬우면서 동시에 분포된 정도도 확인할 수 있는 그래프입니다.

```
seaborn.violinplot(y=some_dataframe)
```

형식으로 사용합니다.

예제: Violin Plot

```
seaborn.violinplot(y=body["Height"])
```

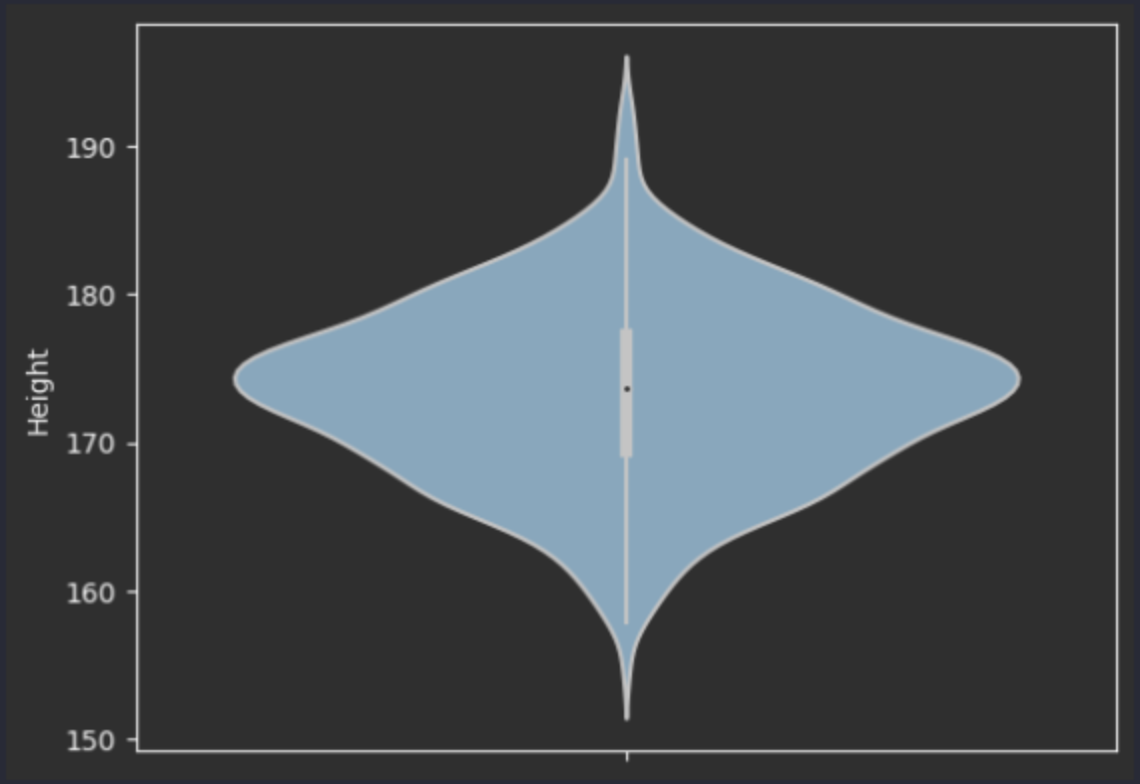

Seaborn - 2차원 KDE Plot

두개의 값을 동시에 KDE 플롯을 그리면
등고선의 형태로 그래프가 그려집니다.

이것을 2차원 KDE Plot이라고 부릅니다.

분산 그래프(산점도)처럼 지표의 상관관계를 파악하며
동시에 분산된 정도도 확인하는데 용이합니다.

```
seaborn.kdeplot(x=some_df["A"], y=some_df["B"])
```

위와 같이 kdeplot 메소드에 두개의 값을 넣어주어 사용합니다.

예제: 2차원 KDE Plot

```
seaborn.kdeplot(x=body["Height"], y=body["Weight"])
```

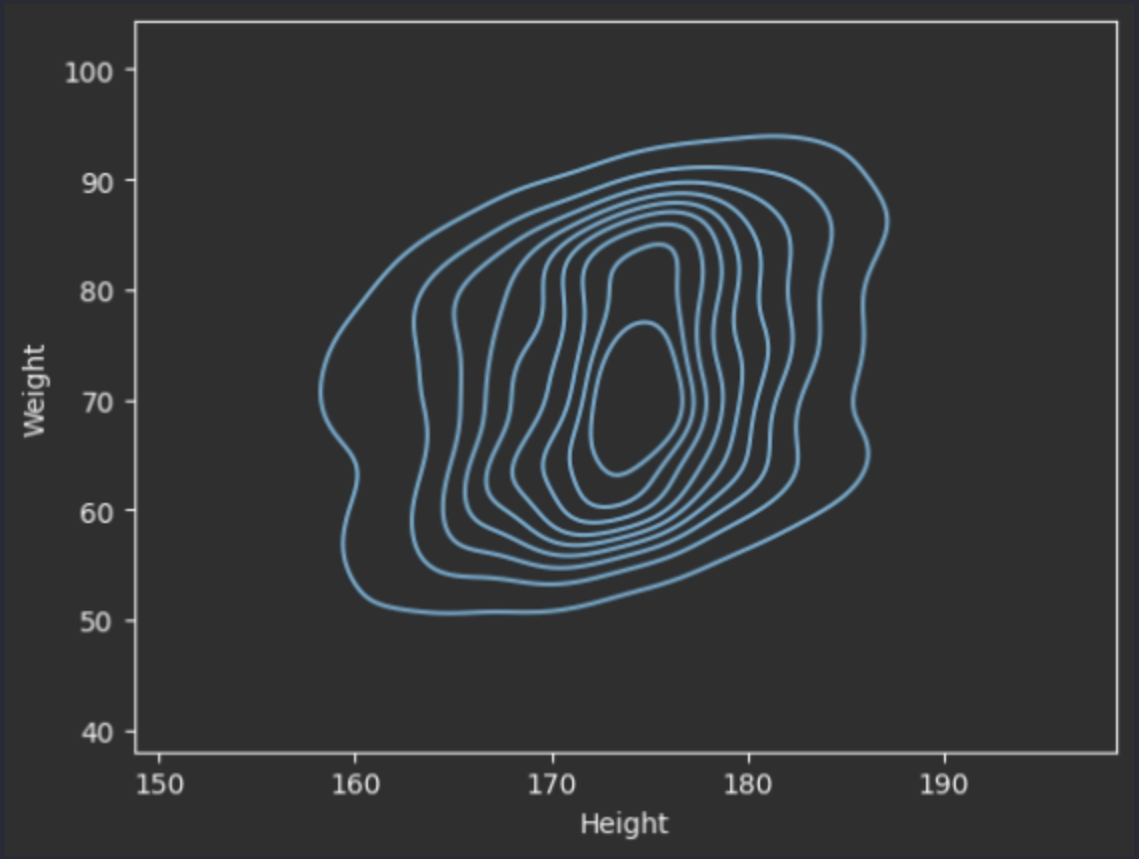

Seaborn - LM Plot

분산 그래프(산점도)에 Regression Line(회귀선)을 그려서 상관관계를 더 단순히 표현하기 위한 그래프입니다.

```
# some_df DataFrame의 column_name_1과 column_name_2의 LM Plot
seaborn.lmplot(data=some_df, x="column_name_1", y="column_name_2")
```

위와 같은 형태로 LM 플롯을 그릴 수 있습니다.

예제: LM Plot

```
seaborn.lmplot(data=body, x="Height", y="Weight")
```

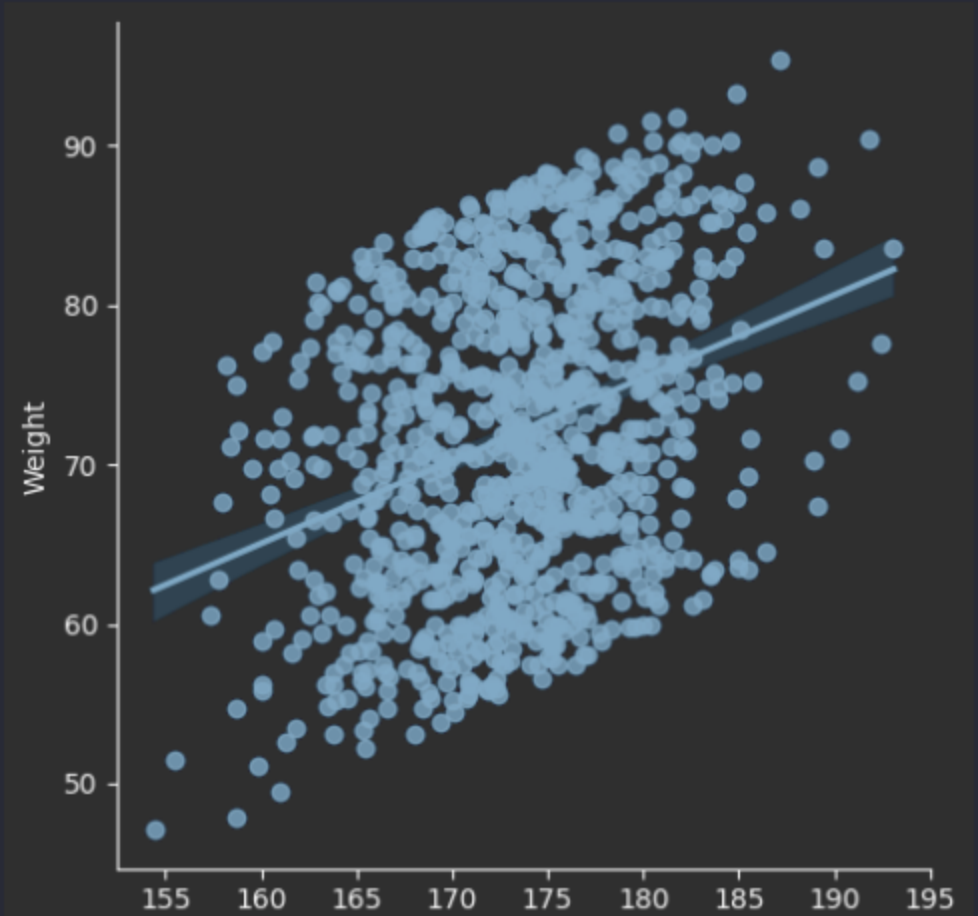

Seaborn - Categorical Plot

데이터를 카테고리별로 묶어서 시각화도 가능합니다.

```
seaborn.catplot(data=some_df, x="col1", y="col2", kind="plot_kind")
```

Categorical scatterplots:

- `stripplot()` (with `kind="strip"`; the default)
- `swarmplot()` (with `kind="swarm"`)

Categorical distribution plots:

- `boxplot()` (with `kind="box"`)
- `violinplot()` (with `kind="violin"`)
- `boxenplot()` (with `kind="boxen"`)

Categorical estimate plots:

- `pointplot()` (with `kind="point"`)
- `barplot()` (with `kind="bar"`)
- `countplot()` (with `kind="count"`)

예제: Categorical Plot

```
Index(['brand', 'model', 'ram', 'hd_type', 'hd_size', 'screen_size', 'price',
       'processor_brand', 'processor_model', 'clock_speed',
       'graphic_card_brand', 'graphic_card_size', 'os', 'weight', 'comments'],
      dtype='object')
```

1-10 167 rows × 15 columns pd.Dataframe CSV

	brand	model	ram	hd_type	hd_size	screen_size	price	processor_brand
0	Dell	Inspiron 15-3567	4	hdd	1024	15.6	40000	intel
1	Apple	MacBook Air	8	ssd	128	13.3	55499	intel
2	Apple	MacBook Air	8	ssd	256	13.3	71500	intel
3	Apple	MacBook Pro	8	ssd	128	13.3	96890	intel
4	Apple	MacBook Pro	8	ssd	256	13.3	112666	intel
5	Apple	MacBook Pro (TouchBar)	16	ssd	512	15.0	226000	intel
6	Apple	MacBook Pro (TouchBar)	16	ssd	512	13.3	158000	intel
7	Apple	MacBook	8	ssd	256	12.0	96990	intel

예제: Categorical Plot

```
# os를 가격별로 그룹화해서 박스 그래프로 표현
seaborn.catplot(laptop, x="os", y="price", kind="box")
```

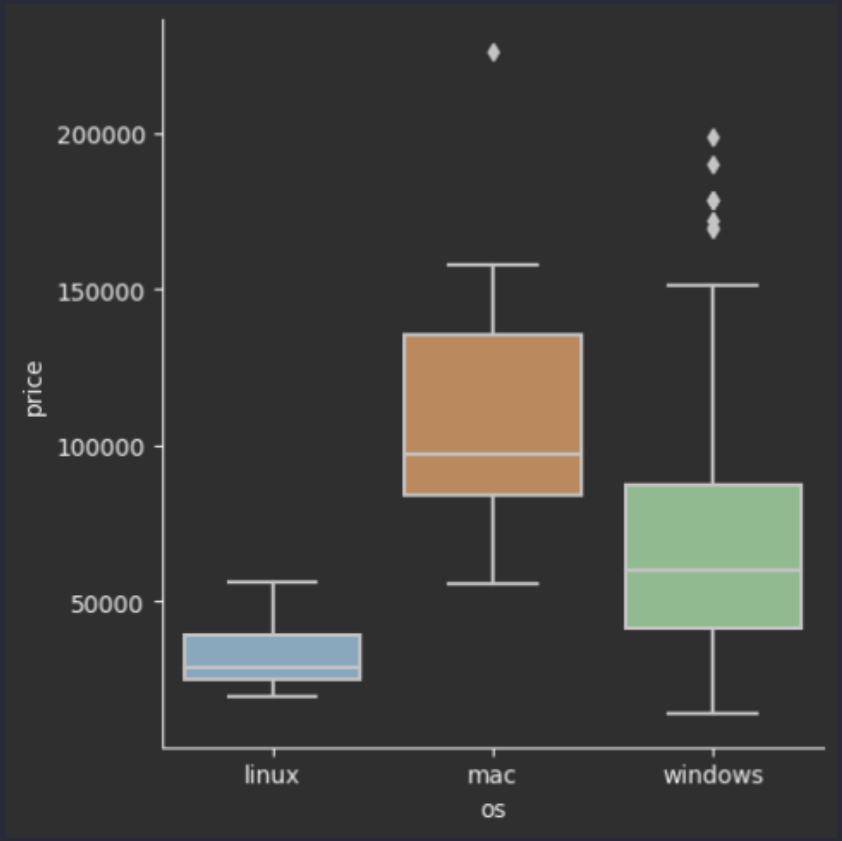

통계 기본 상식 - 중간값

말 그대로 중앙에 있는 값을 말합니다.

[1, 3, 6, 8, 11, 15, 19]
일때의 중간값은 8

[10, 20, 40, 60, 90, 120]
일때의 중간값은 (40 + 60) / 2 = 50

Pearson Correlation Coefficient

피어슨 상관 계수: 두 변수의 연관성을 나타내는 계수입니다.
-1부터 1의 사이의 값만 나올 수 있습니다.

값이 1에 가까운 경우: 연관성이 높음
값이 -1에 가까운 경우: 연관성이 높지만 역의 관계임
값이 0에 가까운 경우: 연관성이 없음

DataFrame - corr

pandas.DataFrame.corr

숫자 데이터 (int, float)의
상관계수 DataFrame을 반환하는 메소드입니다.

아래와 같은 형식으로 사용합니다.

```
some_dataframe.corr()
```

Seaborn - Heatmap

앞에서 corr()을 이용하여 상관계수 DataFrame을 가져왔습니다.
이를 Seaborn의 heatmap 메소드를 이용하면
더 쉽게 볼 수 있습니다.

아래와 같은 형식으로 사용합니다.

```
seaborn.headmap(some_dataframe.corr())
```

예제: Heatmap

```
exam.info()   exam: DataFrame (1000, 8)
```

26ms 내의 2023.05.24 00:24:07에서 실행되었습니다

```
   #   Column                       Non-Null Count  Dtype
  ---  ------                       --------------  -----
   0   gender                       1000 non-null   object
   1   race/ethnicity               1000 non-null   object
   2   parental level of education  1000 non-null   object
   3   lunch                        1000 non-null   object
   4   test preparation course      1000 non-null   object
   5   math score                   1000 non-null   int64
   6   reading score                1000 non-null   int64
   7   writing score                1000 non-null   int64
```

위의 DataFrame을 다시 예제로 봅시다.

예제: Heatmap

```
score = exam[["math score", "reading score", "writing score"]]
seaborn.heatmap(score.corr())
```

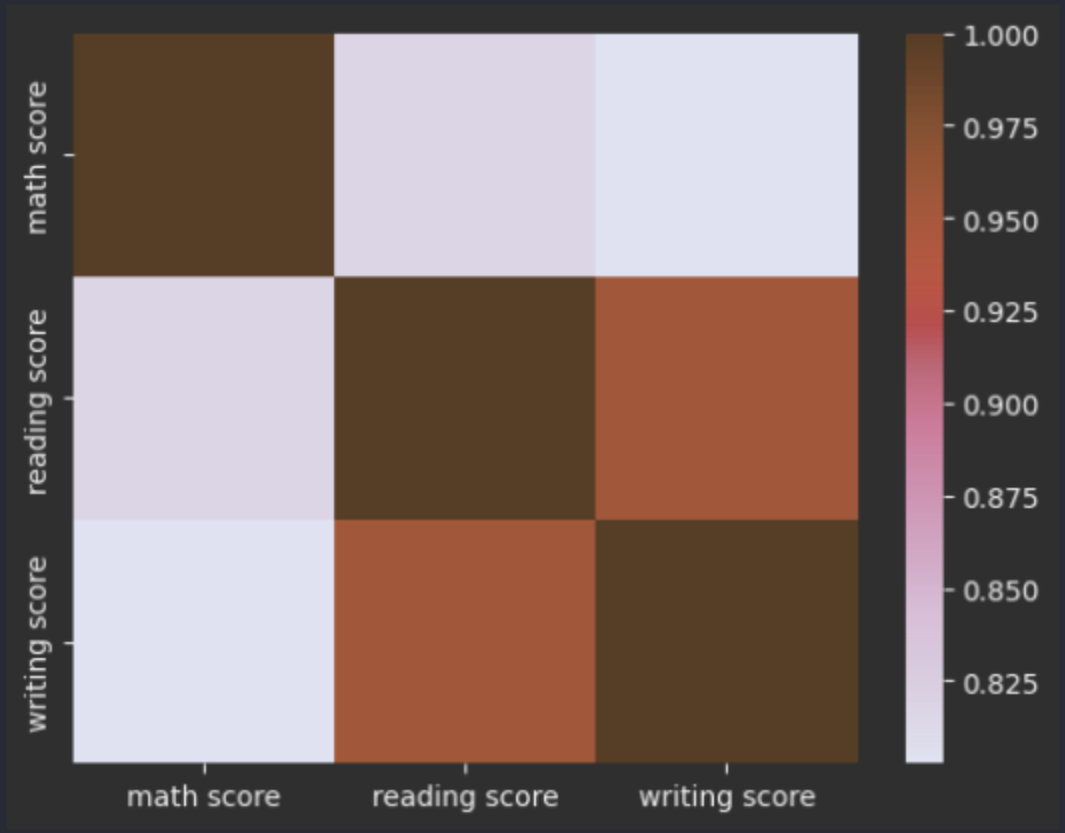

`annot=True` 인수를 추가하면 값도 동시에 출력해 줍니다.

```
score = exam[["math score", "reading score", "writing score"]]
seaborn.heatmap(score.corr(), annot=True)
```

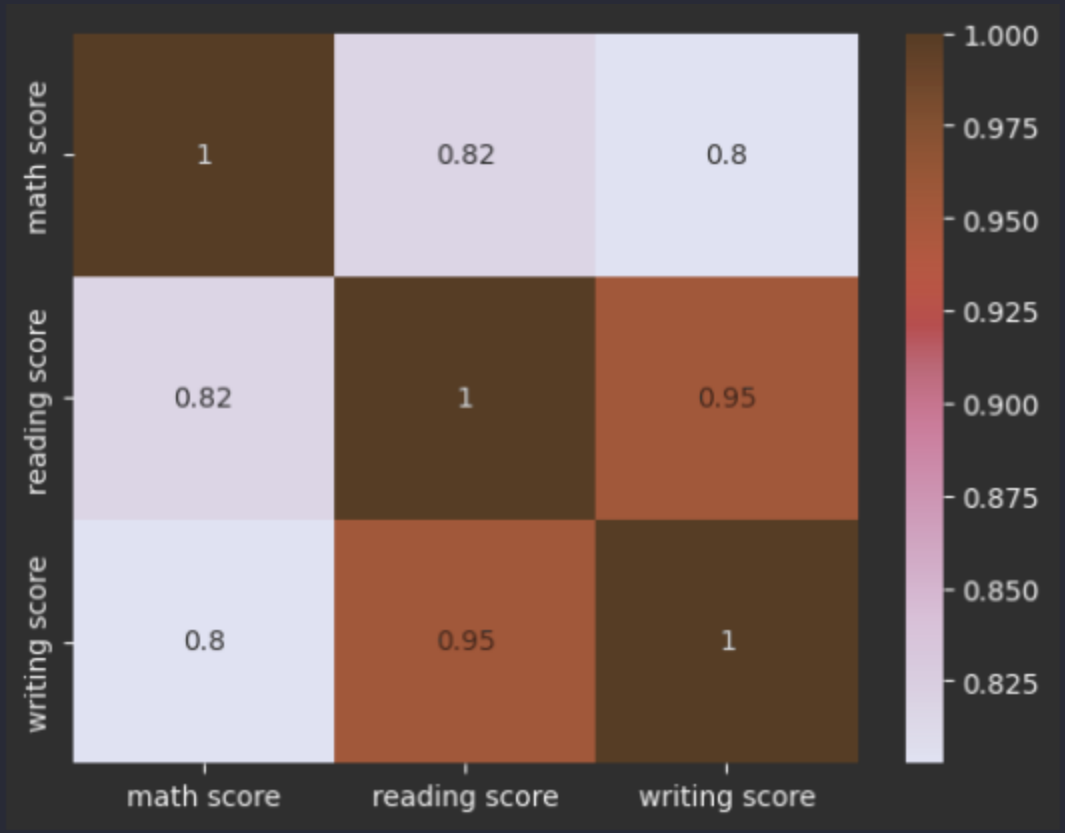

Exploratory Data Analysis

EDA: 데이터를 다양한 관점에서 살펴보며 데이터의 의미를 파악하는것

- 각 row의 의미
- 각 column의 의미
- 데이터의 분포
- column간의 연관성

등을 시각적/통계적인 기법 등으로 데이터를 살펴보며 의미를 파악합니다.

EDA - 기본 정보 파악하기

```
Index(['Music', 'Slow songs or fast songs', 'Dance', 'Folk', 'Country',
       'Classical music', 'Musical', 'Pop', 'Rock', 'Metal or Hardrock',
       ...
       'Spending on looks', 'Spending on gadgets',
       'Spending on healthy eating', 'Age', 'Height', 'Weight',
       'Number of siblings', 'Gender', 'Handedness', 'Education'],
      dtype='object', length=147)
```

1-10 997 rows × 147 columns pd.Dataframe CSV

	Music	Slow songs or fast songs	Dance	Folk	Country	Classical music	Musical	Pop	Rock
0	5.0	3.0	2.0	1.0	2.0	2.0	1.0	5.0	5.0
1	4.0	4.0	2.0	1.0	1.0	1.0	2.0	3.0	5.0
2	5.0	5.0	2.0	2.0	3.0	4.0	5.0	3.0	5.0
3	5.0	3.0	2.0	1.0	1.0	1.0	1.0	2.0	2.0
4	5.0	3.0	4.0	3.0	2.0	4.0	3.0	5.0	3.0
5	5.0	3.0	2.0	3.0	2.0	3.0	3.0	2.0	5.0
6	5.0	5.0	5.0	3.0	1.0	2.0	2.0	5.0	3.0
7	5.0	3.0	3.0	2.0	1.0	2.0	2.0	4.0	5.0

위와 같은 DataFrame을 예로 봅시다.

예제 - 설문조사 참가자 기본 정보

Column의 마지막 7개가
각각 나이, 키 몸무게, 형제 수, 성별, 오른손/왼손잡이, 학력을 나타내는것을 알 수 있습니다.

총 147개의 column이 있으니 140~146번째의 column이겠죠.

이런 경우 iloc를 이용하여 쉽게 가져올 수 있습니다.

```
basics = young_survey.iloc[:, 140:]  # 140~마지막까지의 col을 가져옴
```

결과 - 설문조사 참가자 기본 정보

	Age	Height	Weight	Number of siblings	Gender	Handedness	Education
0	20.0	163.0	48.0	1.0	female	right	bachelor's degree
1	19.0	163.0	58.0	2.0	female	right	bachelor's degree
2	20.0	176.0	67.0	2.0	female	right	high school
3	22.0	172.0	59.0	1.0	female	right	bachelor's degree
4	20.0	170.0	59.0	1.0	female	right	high school
5	20.0	186.0	77.0	1.0	male	right	high school
6	20.0	177.0	50.0	1.0	female	right	high school
7	19.0	184.0	90.0	1.0	male	right	bachelor's degree

위와 같이 참가자들의 기본 정보를 가져온 것을 볼 수 있습니다.

예제 - 성별

기본 정보만을 추려냈으니, 더 쉽게 참가자의 정보를 알 수 있습니다.
예를 들어서 참가자들의 성비를 알고 싶다면

```
basics["Gender"].value_counts()
```

를 이용하면 되겠죠.
더 나아가서 시각적으로 보고 싶다면

```
basics["Gender"].value_counts().plot(kind="pie")
```

를 하면 되겠죠.

결과 - 성별

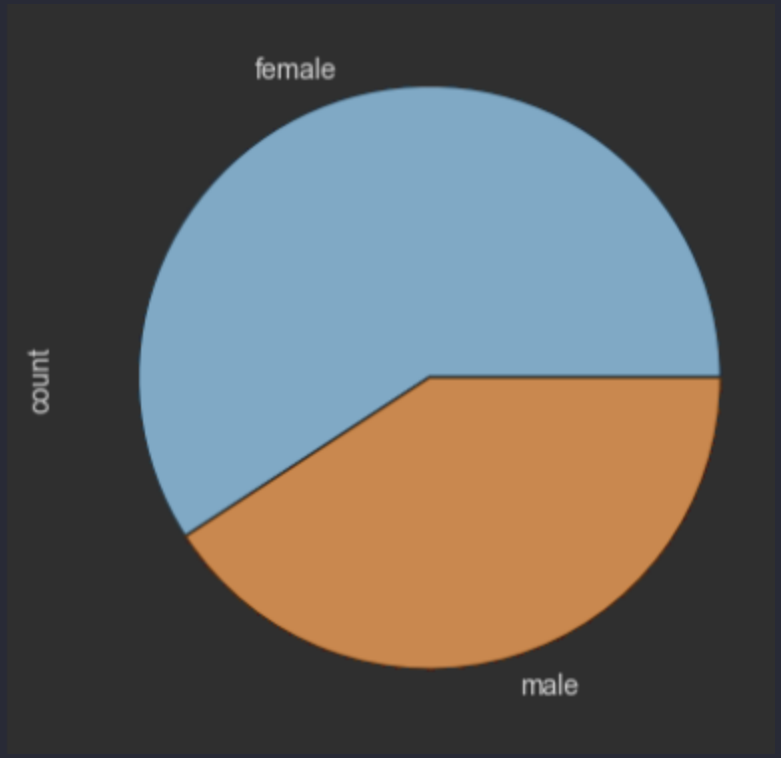

위의 일련의 과정을 통해 참가자는 여성이 더 많다는 것을 쉽게 확인할 수 있습니다.

예제 - 연령 분포

이번에는 연령 분포를 알아봅시다.

```
basics["Age"].value_counts()
```

성별과 마찬가지로 Age column의 value_counts()를 가져오면 되겠죠. 마찬가지로 시각적으로 보고 싶다면

```
seaborn.violinplot(data=basics, y="Age")
```

를 하면 되겟죠.

결과 - 연령 분포

```
<Axes: ylabel='Age'>
```

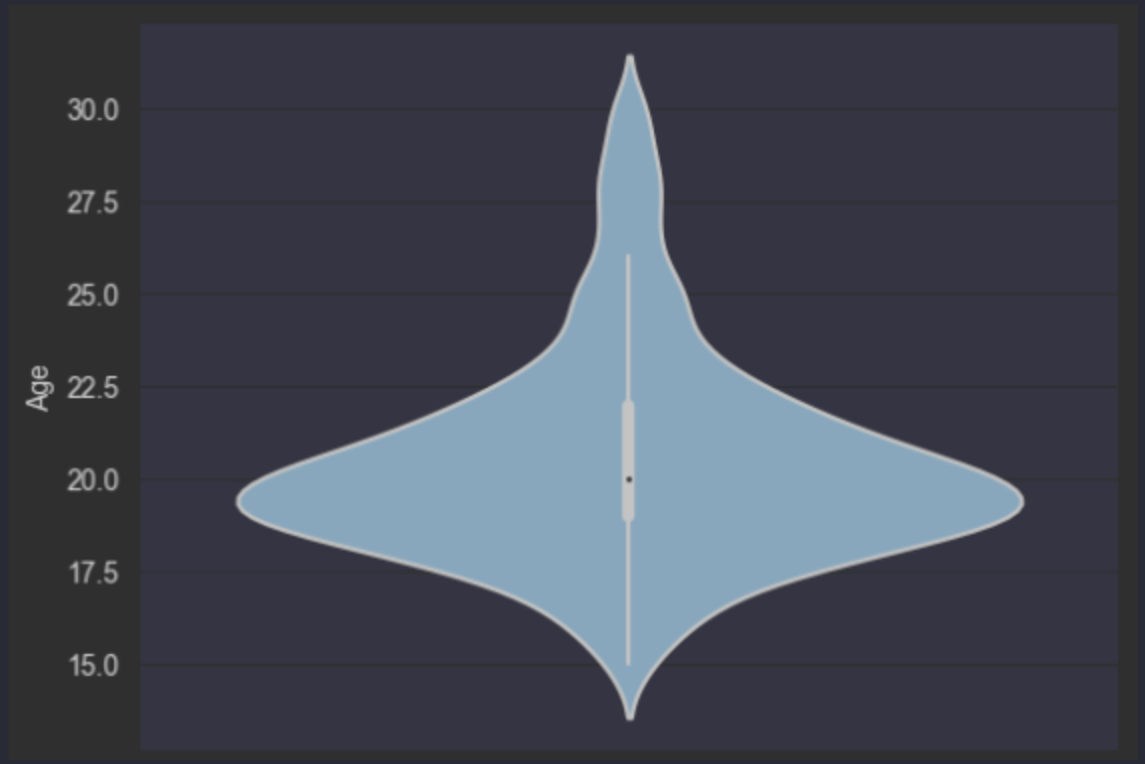

위를 통해 17살~20살 사이가 가장 참가자가 많은 것을 알 수 있습니다

예제 - 성별별 연령 분포

성별마다 따로 연령 분포를 알고 싶다면 어떻게 하면 될까요?
단순히 `violinplot()`에 `x="Gender"`을 추가해주면 됩니다.

```
seaborn.violinplot(data=basics, y="Age", x="Gender")
```

결과 - 성별별 연령 분포

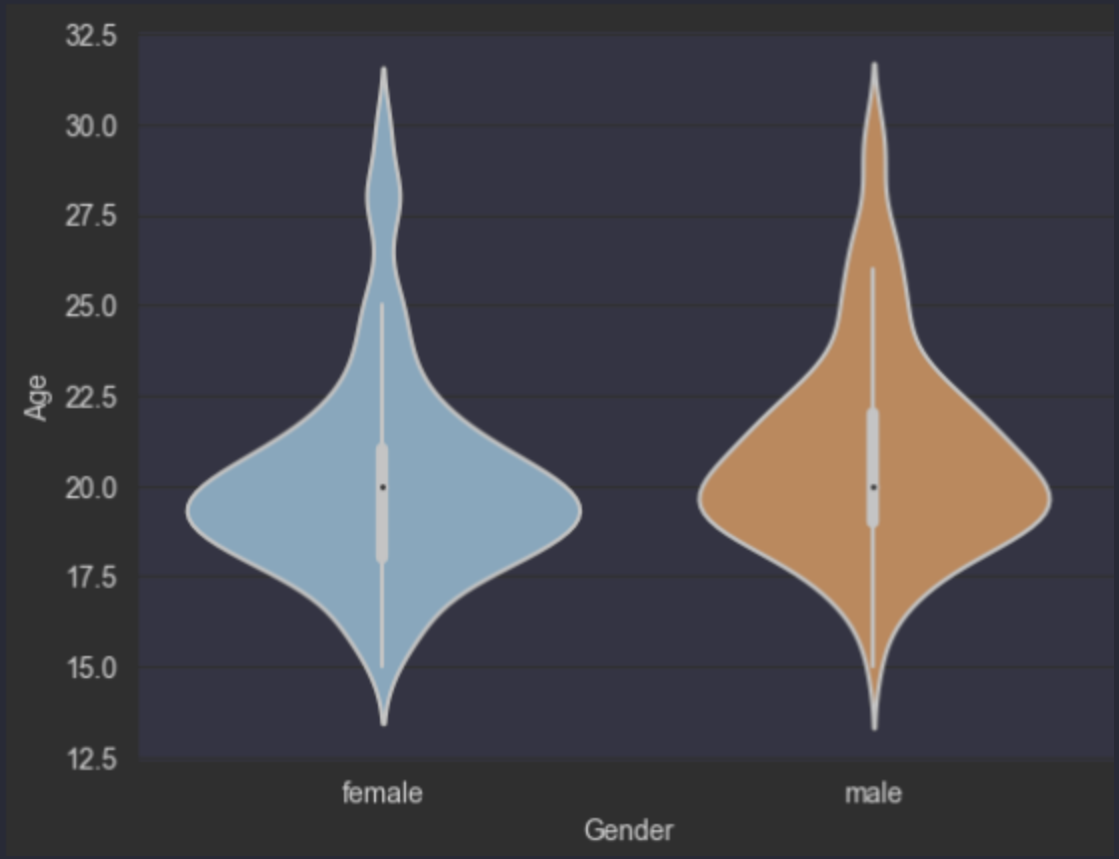

남성/여성 모두 성별 분포가 비슷한 것을 알 수 있습니다.

상관 관계 분석

pandas.DataFrame의 corr() 메소드와
seaborn의 heatmap() 메소드를 이용하면
쉽게 column간의 상관관계를 파악할 수 있습니다.

예제 - 음악 선호도 간의 상관관계

다시 young_survey DataFrame을 살펴보면
0번부터 19번까지가 음악 선호도에 관한 column인것을 알 수 있습니다.
이것들의 상관계수를 구하려면

```
music_corr = young_survey.iloc[:, :19].corr()
```

을 이용하면 되겠죠. 이것을 시각화하려면

```
seaborn.heatmap(music_corr)
```

을 이용하면 됩니다.

결과 - 음악 선호도 간의 상관관계

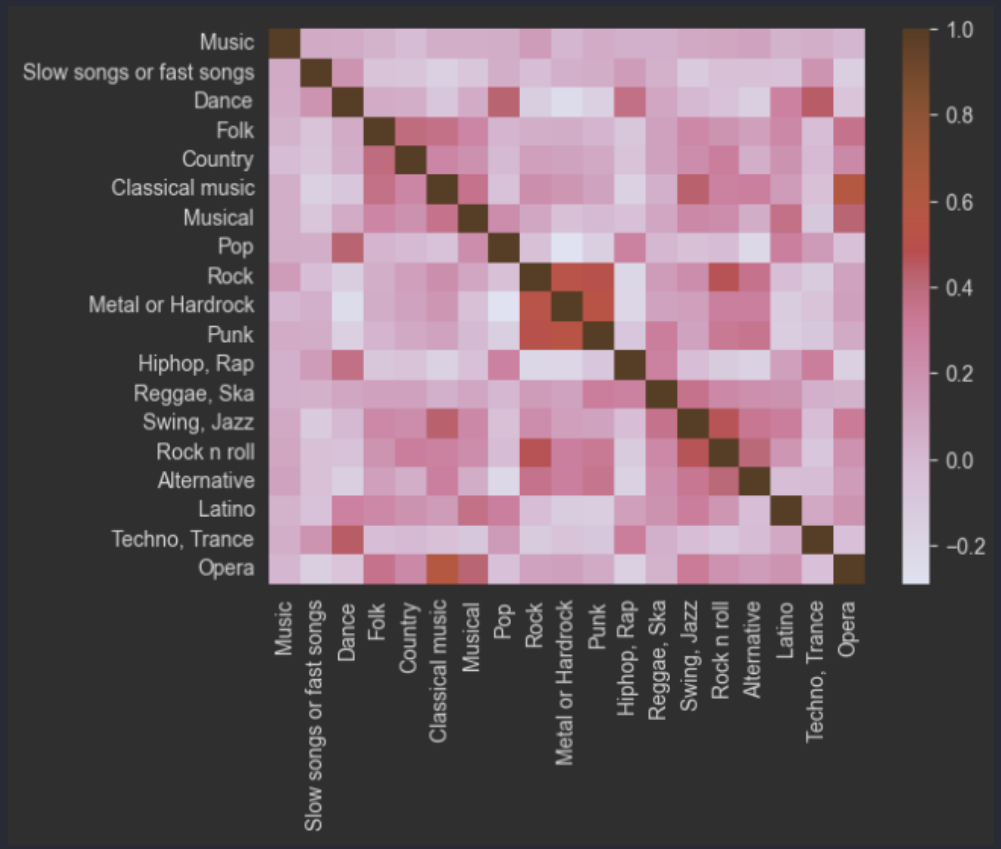

위의 Heatmap을 통해 음악 장르 선호도 간의 상관관계를 알 수 있습니다.
예를 들면 색이 진한 펑크와 락은 서로 겹치는 팬층이 많다고 해석할 수 있겠죠.

Cluster Analysis

요소들을 비슷한 경향을 가진 집단으로 묶는 것을
클러스터 분석이라고 합니다.

비슷한 경향 = 상관관계가 높음

일테니까 상관계수가 높은 요소끼리 묶으면 좋겠죠.

예제 - Cluster Analysis

young_survey DataFrame을 다시 살펴보면,
History column부터 Pets column까지가
관심사에 관한 것임을 알 수 있습니다.

이것들의 상관 관계를 구하려면

```
interests = young_survey.loc[:, "History":"Pets"].corr()
```

를 해주면 되겠죠.

예제 - Cluster Analysis

Seaborn에는 클러스터링을 하기 쉽게 도와주는 clustermap 메소드가 존재합니다.

기본적으로 Heatmap을 기반으로 하는 플롯이죠.

위에서 구한 관심사들을 클러스터링 하려면 다음과 같이 사용하면 됩니다.

```
seaborn.clustermap(interests)
```

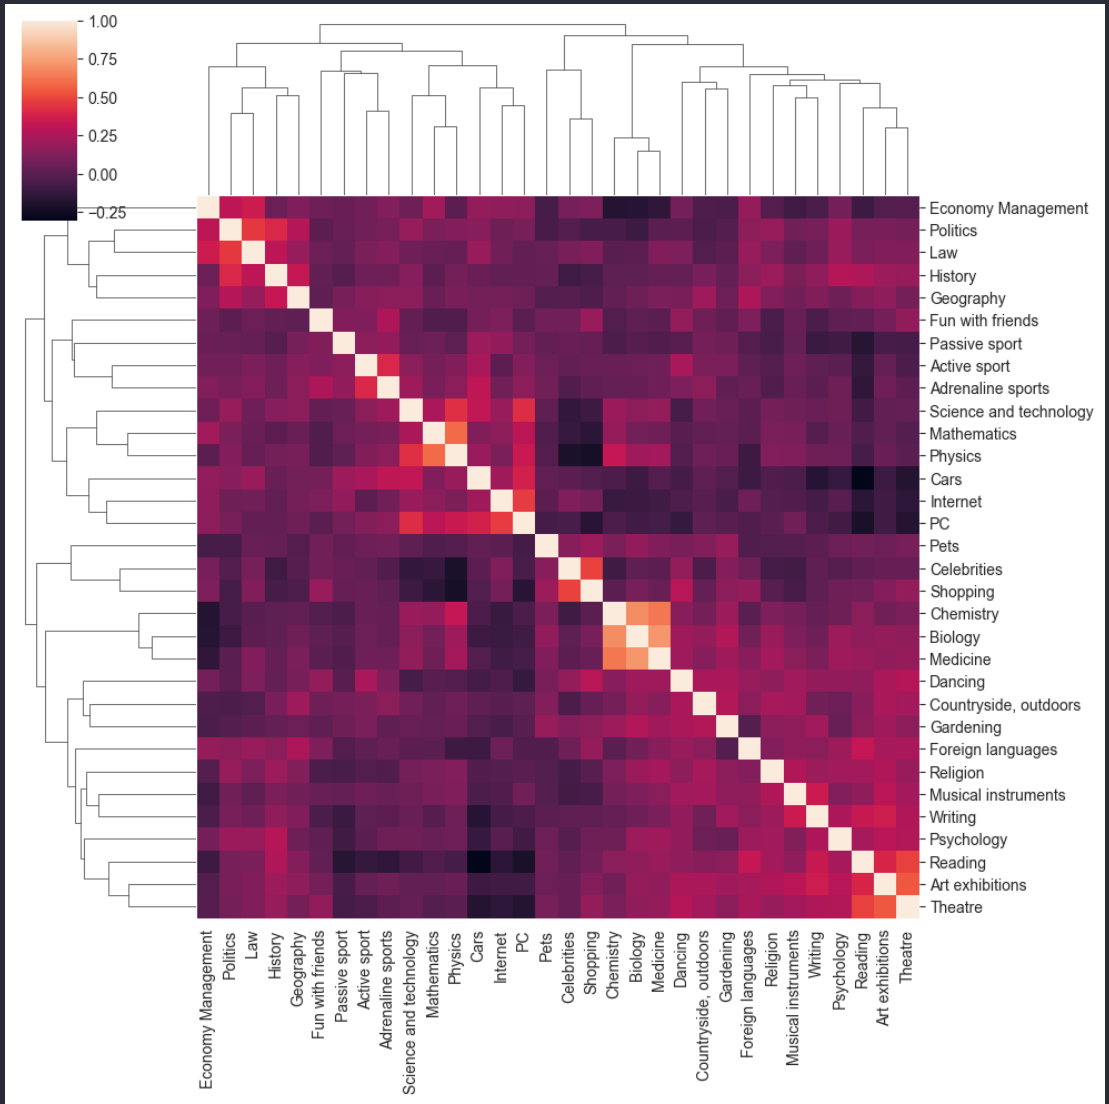

위와 같이 상관계수가 높은 column 끼리 묶어서 표현해주는것을 알 수 있습니다.

DataFrame - sum

pandas.DataFrame.sum

DataFrame의 sum 메소드를 이용해서
index나 column의 합을 구할 수 있습니다.

```
some_dataframe.sum(axis="columns")   # Column의 합
some_dataframe.sum(axis="index")     # index의 합
```

예제: sum

	KBS	MBC	SBS	TV CHOSUN	JTBC	Channel A	MBN
2011	35.951	18.374	11.173	9.102	7.380	3.771	2.809
2012	36.163	16.022	11.408	8.785	7.878	5.874	3.310
2013	31.989	16.778	9.673	9.026	7.810	5.350	3.825
2014	31.210	15.663	9.108	9.440	7.490	5.776	4.572
2015	27.777	16.573	9.099	9.940	7.267	6.678	5.520
2016	27.583	14.982	8.669	9.829	7.727	6.624	5.477
2017	26.890	12.465	8.661	8.886	9.453	6.056	5.215

위의 DataFrame을 예제로 봅시다.

예제: sum

년도별로 시청률의 합계를 구하려면 column끼리 더하면 되겠죠.

```
total = broadcast.sum(axis="columns")
```

	<unnamed>
2011	88.560
2012	89.440
2013	84.451
2014	83.259
2015	82.854
2016	80.891
2017	77.626

`sum(axis="columns")` 로 column의 합계를 볼 수 있습니다.

이 합계를 원본 DataFrame의 새로운 column으로 넣어봅시다.

```
broadcast["Total"] = total
```

	KBS	MBC	SBS	TV CHOSUN	JTBC	Channel A	MBN	Total
2011	35.951	18.374	11.173	9.102	7.380	3.771	2.809	88.560
2012	36.163	16.022	11.408	8.785	7.878	5.874	3.310	89.440
2013	31.989	16.778	9.673	9.026	7.810	5.350	3.825	84.451
2014	31.210	15.663	9.108	9.440	7.490	5.776	4.572	83.259
2015	27.777	16.573	9.099	9.940	7.267	6.678	5.520	82.854
2016	27.583	14.982	8.669	9.829	7.727	6.624	5.477	80.891
2017	26.890	12.465	8.661	8.886	9.453	6.056	5.215	77.626

기존 값들을 통해 새로운 값을 만들어 내면,
이전의 데이터만으로는 볼 수 없던 새로운 정보를
알아낼수도 있습니다.

Total을 시각화해보면

```
df.plot(kind="line", y="Total")
```

이렇게 점점 TV 시청률이 줄어드는것을 알 수 있습니다.

Series - str

pandas.Series의 str프로퍼티를 이용하면
각각의 문자열에 대한 조작을 할 수 있습니다.

파이썬 map()함수나 JS의 Array.map() 메소드랑 비슷하네요.

예제: str

Number	Year	Album	Artist	Genre	Subgenre
1	1967	Sgt. Pepper's Lonely Hearts Club Ba…	The Beatles	Rock	Rock & Roll
2	1966	Pet Sounds	The Beach Boys	Rock	Pop Rock, P
3	1966	Revolver	The Beatles	Rock	Psychedelic
4	1965	Highway 61 Revisited	Bob Dylan	Rock	Folk Rock,
5	1965	Rubber Soul	The Beatles	Rock, Pop	Pop Rock
6	1971	What's Going On	Marvin Gaye	Funk / Soul	Soul
7	1972	Exile on Main St.	The Rolling Stones	Rock	Blues Rock,

위의 DataFrame의 예제로 봅시다.

예제: str

Genre가 Rock를 포함하는 모든 열을
가져오고 싶다고 해 봅시다.

```
has_rock = album["Genre"].str.contains("Rock")
```

위의 코드를 통해 Genre column의 모든 데이터에 대해
`contains()` (파이썬 문자열 빌트인 메소드)를
실행시킬 수 있습니다.
실행시킨 결과는 새로운 Series를 통해서 반환됩니다.
즉, Genre에 "Rock"을 포함하는 열은 True를,
아닌 열은 False인 Series가 반환된다는 소리입니다.

위의 Series를 통해 원본 DataFrame을 필터링하면

```
album.loc[has_rock]
```

Number	Year	Album	Artist	Genre	Subgenre
2	1966	Pet Sounds	The Beach Boys	Rock	Pop Rock, P
3	1966	Revolver	The Beatles	Rock	Psychedelic
4	1965	Highway 61 Revisited	Bob Dylan	Rock	Folk Rock,
5	1965	Rubber Soul	The Beatles	Rock, Pop	Pop Rock
7	1972	Exile on Main St.	The Rolling Stones	Rock	Blues Rock,
8	1979	London Calling	The Clash	Rock	Punk, New W
9	1966	Blonde on Blonde	Bob Dylan	Rock, Blues	Folk Rock,
10	1968	The Beatles ("The White Album")	The Beatles	Rock	Rock & Roll

Genre가 Rock을 포함하는 모든 row가 출력됩니다.

Series - str.split

파이썬에서 문자열의 split 메소드는 원하는 문자열을 기준으로 문자열을 분리해서 새로운 리스트로 만들어 주는 메소드입니다.

pandas.Series의 str프로퍼티에도 split이 구현되어 있고, 일반적인 split과 다르게 분리된 문자열을 새로운 DataFrame으로 만들 수도 있습니다.

```
# 문자열을 "/" 기준으로 나눠서 Series로 반환
some_df["some_str_col"].str.split("/")

# 문자열을 공백 (띄어쓰기) 기준으로 1번만 나누고, DataFrame으로 반환
some_df["some_str_col"].str.split(n=1, expand=True)
```

예제: str.split

관리번호	공원명	공원구분	소재지도로명주소	전화번호
29170-00001	문화근린공원	근린공원	광주광역시 북구 대천로 86	062-410-6438
29170-00002	두암제1근린공원	근린공원	광주광역시 북구 삼정로 36	062-410-6438
29170-00003	첨단체육근린공원	근린공원	광주광역시 북구 임방울대로 877	062-410-6438
29170-00004	일곡제1근린공원	근린공원	광주광역시 북구 일곡로 55	062-410-6438
29170-00005	일곡제2근린공원	근린공원	광주광역시 북구 설죽로 526	062-410-6438
29170-00006	일곡제3근린공원	근린공원	광주광역시 북구 양일로 297	062-410-6438
29170-00007	첨단2주거1호근린	근린공원	광주광역시 북구 첨단연신로107번길	062-410-6438

위의 DataFrame을 예제로 봅시다.

예제: str.split

소재지도로명주소에서 관할구역 (도/특별시/광역시)을 분리하고 싶다고 하면

```
state = parks["소재지도로명주소"].str.split(n=1, expand=True)
```

관리번호	0	1
29170-00001	광주광역	북구 대천로 86
29170-00002	광주광역	북구 삼정로 36
29170-00003	광주광역	북구 임방울대로 877
29170-00004	광주광역	북구 일곡로 55
29170-00005	광주광역	북구 설죽로 526
29170-00006	광주광역	북구 양일로 297
29170-00007	광주광역	북구 첨단연신로107번

이걸 새로운 column으로 넣어주려면 아래와 같습니다.

```
parks["관할구역"] = state[0]
```

관리번호	공원명	공원구분	소재지도로명주소	전화번호	관할구역
29170-00001	문화근린공원	근린공원	광주광역시 북구 대천로 86	062-410-6438	광주광역시
29170-00002	두암제1근린공원	근린공원	광주광역시 북구 삼정로 36	062-410-6438	광주광역시
29170-00003	첨단체육근린공원	근린공원	광주광역시 북구 임방울대로 877	062-410-6438	광주광역시
29170-00004	일곡제1근린공원	근린공원	광주광역시 북구 일곡로 55	062-410-6438	광주광역시
29170-00005	일곡제2근린공원	근린공원	광주광역시 북구 설죽로 526	062-410-6438	광주광역시
29170-00006	일곡제3근린공원	근린공원	광주광역시 북구 양일로 297	062-410-6438	광주광역시
29170-00007	첨단2주거1호근린	근린공원	광주광역시 북구 첨단연신로107번	062-410-6438	광주광역시

Series - map

pandas.Series의 map 메소드를 통해서,
각각의 값을 다른 값으로 변환해 줄 수 있습니다.

```
col_map_dict = {
    "A": "Group 1",
    "B": "Group 1",
    "C": "Group 2"
}

 # A, B는 Group 1, C는 Group 2로 변환해서 Series로 반환
some_df["col"].map(col_map_dict)
```

예제: map

```
Index(['brand', 'model', 'ram', 'hd_type', 'hd_size', 'screen_size', 'price',
       'processor_brand', 'processor_model', 'clock_speed',
       'graphic_card_brand', 'graphic_card_size', 'os', 'weight', 'comments'],
      dtype='object')
```

1-10 167 rows × 15 columns pd.Dataframe CSV

	brand	model	ram	hd_type	hd_size	screen_size	price	processor_brand
0	Dell	Inspiron 15-3567	4	hdd	1024	15.6	40000	intel
1	Apple	MacBook Air	8	ssd	128	13.3	55499	intel
2	Apple	MacBook Air	8	ssd	256	13.3	71500	intel
3	Apple	MacBook Pro	8	ssd	128	13.3	96890	intel
4	Apple	MacBook Pro	8	ssd	256	13.3	112666	intel
5	Apple	MacBook Pro (TouchBar)	16	ssd	512	15.0	226000	intel
6	Apple	MacBook Pro (TouchBar)	16	ssd	512	13.3	158000	intel
7	Apple	MacBook	8	ssd	256	12.0	96990	intel

위의 예제로 봅시다.

예제: map

brand (제조사)의 국적은 다음과 같습니다.

- Dell, Apple, Ailenware, Microsoft = 미국
- Acer, Asus = 대만
- Lenovo = 중국

이를 dict로 변환하면 아래와 같습니다.

```
brand_nationality = {
    "Dell": "U.S","Apple": "U.S","Ailenware": "U.S","Microsoft": "U.S",
    "Acer": "Taiwan", "Asus": "Taiwan", "Lenovo": "China"
}
```

이를 map을 통해 변환하면

```
nat = laptop["brand"].map(brand_nationality)
```

	brand
10	U.S
11	U.S
12	U.S
13	U.S
14	U.S
15	Taiwan
16	U.S
17	Taiwan

위와 같이 brand에 맞는 국적의 Series가 반환됩니다.

이것을 원본 DataFrame에 넣어주면

```
laptop["Nationality"] = nat
```

peed	graphic_card_brand	graphic_card_size	os	weight	comments	Nationality
2.5	intel	NaN	linux	2.50	NaN	U.S
1.8	intel	2.0	mac	1.35	NaN	U.S
1.8	intel	2.0	mac	1.35	NaN	U.S
2.3	intel	2.0	mac	3.02	NaN	U.S
2.3	intel	2.0	mac	3.02	NaN	U.S
2.7	intel	2.0	mac	2.50	NaN	U.S
2.9	intel	2.0	mac	1.37	NaN	U.S
1.2	intel	2.0	mac	0.92	NaN	U.S

국적이 추가되는것을 볼 수 있습니다.

DataFrame - groupby

pandas.DataFrame.groupby

groupby 메소드를 통해서 특정 column의 값에 따라 그룹화 할 수 있습니다.

```
# some_dataframe을 "col" column의 값이 같은 row마다 그룹화
some_dataframe.groupby("col")
```

DataFrame - groupby.count

groupby를 통해 묶어준 DataFrame의 column별 값의 개수를 알 수 있습니다.

```
laptop.groupby("Nationality").count()
```

Nationality	brand	model	ram	hd_type	hd_size	screen_size	price	processor_
China	18	18	18	18	18	18	18	
Taiwan	44	44	44	44	44	44	44	
U.S	44	44	44	44	44	44	44	

DataFrame - groupby.max / groupby.min

max, min 메소드로 각 그룹의 최대/최소값을 알 수 있습니다.

```
laptop.groupby("Nationality").max()
```

Nationality	ram	hd_size	screen_size	price	clock_speed
China	8	2048	15.6	69990	3.5
Taiwan	16	1024	17.3	178912	3.6
U.S	16	2048	15.6	226000	3.8

DataFrame - groupby 기타 메소드

- mean(): 각 그룹의 평균값
- first(): 각 그룹의 첫번째 값
- last(): 각 그룹의 마지막 값
- plot(): 일반 DataFrame과 마찬가지로 시각화 가능

DataFrame - merge

pandas.DataFrame.merge

RDB의 TABLE JOIN과 같이,
DataFrame과 다른 DataFrame을 합치는 메소드

```
# some_df와 another_df의 key column을 기준으로 letf join
pandas.merge(some_df, another_df, on="key", how="left")
```

DataFrame - Merge Type

Merge 방식도 SQL의 JOIN과 똑같습니다.

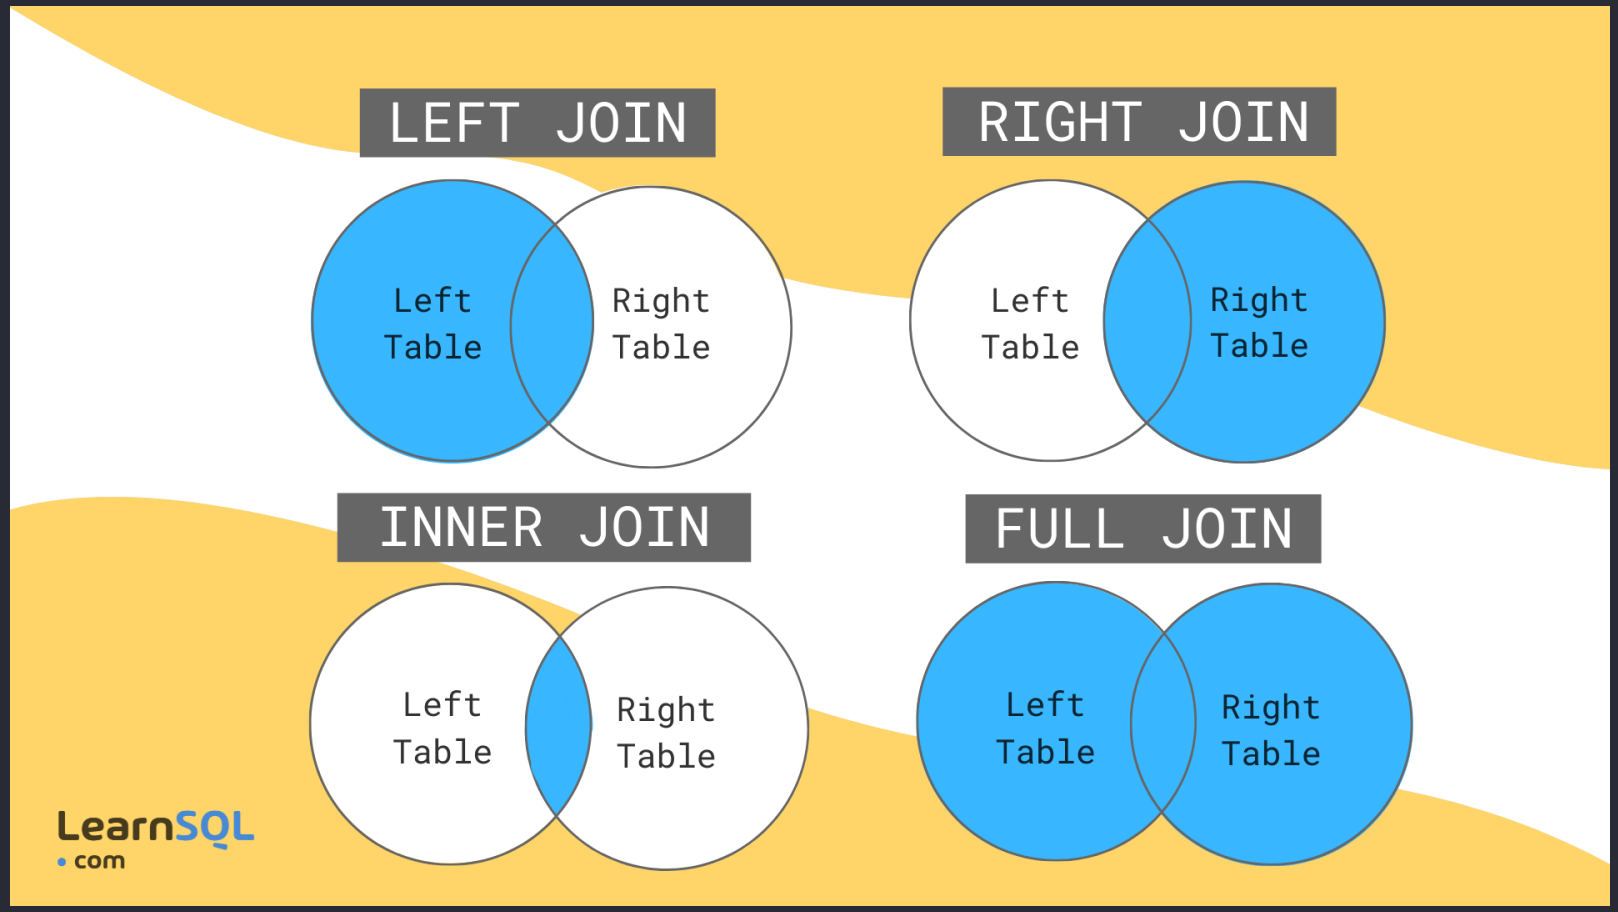

예제: Merge

Product	Quantity
Potato	25
Onion	31
Avocado	57
Pepper	46
Broccoli	25
Cucumber	9

Product	Price
Potato	3000
Onion	1600
Avocado	5000
Garlic	1200
Tomato	3500
Lettuce	2000
Carrot	2500

위와 같은 DataFrame을 예제로 봅시다.

예제: Inner Join

```
pandas.merge(quantity, price, on="Product", how="inner")
```

Product	Quantity	Price
Potato	25	3000
Onion	31	1600
Avocado	57	5000

left (quantity), right(price) 양쪽 모두에 존재하는 Potato, Onion, Avocado row만 병합된것을 볼 수 있습니다.

예제: Left Join

```
pandas.merge(quantity, price, on="Product", how="left")
```

Product	Quantity	Price
Potato	25	3000.0
Onion	31	1600.0
Avocado	57	5000.0
Pepper	46	NaN
Broccoli	25	NaN
Cucumber	9	NaN

왼쪽 (quantity)에 존재하는 값은 모두 표시되지만,
오른쪽 (price)에 존재하는 값은 서로 중복되는 값을 제외하고는
병합되지 않는것을 볼 수 있습니다.

예제: Right Join

```
pandas.merge(quantity, price, on="Product", how="right")
```

Product	Quantity	Price
Potato	25.0	3000
Onion	31.0	1600
Avocado	57.0	5000
Garlic	NaN	1200
Tomato	NaN	3500
Lettuce	NaN	2000
Carrot	NaN	2500

오른쪽 (price)에 존재하는 값은 모두 표시되지만,
왼쪽 (quantity)에 존재하는 값은 서로 중복되는 값을 제외하고는
병합되지 않는것을 볼 수 있습니다.

예제: Full Outer Join

```
pandas.merge(quantity, price, on="Product", how="outer")
```

Product	Quantity	Price
Pepper	46.0	NaN
Broccoli	25.0	NaN
Cucumber	9.0	NaN
Garlic	NaN	1200.0
Tomato	NaN	3500.0
Lettuce	NaN	2000.0
Carrot	NaN	2500.0

중복되지 않는 값들도 모두 병합되서
출력되는것을 볼 수 있습니다.